

Feline Leukemia Virus - FeLV

Protocolo de análise

Protocolo de análise desenvolvido por Dennis Maletich Junqueira, Taylice Leonel Batista e Bruna Bolina da Cunha e versão final revisada por Dennis Maletich Junqueira

Sumário:

Objetivo do protocolo	01
Observações	02
Pasta referente ao projeto	02
Obtenção dos dados	02
Salvando arquivos	03
Adição de sequências-referência	04
Controle de qualidade das sequências	04
Subtipagem das sequências	05
Inclusão de colunas na tabela de metadados	05
Modificando o nome das sequências	06
Selecionando as sequências para o dataset final pré-alinhamento	07
Alinhamento e edição das sequências	07
Identificação do tamanho das sequências	08
Identificação de sequências duplicadas	09
Identificação de sequências recombinantes	09
Reconstrução filogenética	09
Visualização da árvore filogenética	09
Anexo I (<i>CheckList</i> para construção de datasets e análises)	10

Objetivo do protocolo:

Descrever e padronizar o fluxo de análise de sequências biológicas do Vírus da Leucemia Felina (FeLV), contemplando etapas de obtenção de dados, curadoria de metadados, alinhamento, subtipagem, identificação de recombinantes, análises de diversidade genética, reconstrução filogenética e interpretação dos resultados.

Observações:

Neste documento, os seguintes termos são usados amplamente:

- a) Código do tipo de informação (CTI): para facilitar a identificação rápida do conteúdo dos arquivos manuseados nas análises, adota-se o seguinte padrão para a codificação de informação:
 - 00 Arquivos relacionados aos metadados
 - 01 Arquivos relacionados às sequências biológicas
 - 02 Arquivos relacionados às filogenias
 - 03 Demais arquivos
- b) Formato FASTA: arquivo de sequências biológicas no formato .fas ou .fasta.
- c) Metadados: refere-se ao conjunto de informações que podem acompanhar a sequência biológica da amostra, como data de coleta, informações geográficas, hospedeiro, linhagem etc.
- d) Sequências biológicas: refere-se às sequências de nucleotídeos e/ou aminoácidos de genes, segmentos e/ou genomas.

Pasta referente ao projeto:

- a) Para iniciar um novo projeto, crie uma **pasta com o nome do Projeto**. Mantenha um nome simples, direto e evite acentos, espaços e caracteres incomuns.
- b) Dentro desta pasta, crie uma **subpasta chamada Analise_01**. Este procedimento é para garantir que, caso seja necessário recomençar o projeto, os dados iniciais não sejam perdidos. Não é incomum ter que recomençar um projeto seja pela adição de novas sequências, problemas de amostragem e/ou falta de sequências.

Obtenção dos dados:

- a) Os principais bancos de dados para a busca de sequências do vírus são:
 - GenBank: <https://www.ncbi.nlm.nih.gov/genbank/>
 - NCBIvirus: <https://www.ncbi.nlm.nih.gov/labs/virus/vssi/#/>
- b) Nestes bancos de dados, você deve buscar as sequências biológicas e as informações de metadados.
- c) Enquanto outros bancos de dados permitem facilmente a obtenção de metadados e informações sobre as próprias sequências genéticas (como região gênica da sequência-alvo), o GenBank é muito menos permissível. Desta maneira, caso você necessite fazer buscas de sequências biológicas no GenBank, a melhor alternativa é utilizar o script a seguir

002R109 Sequence GenbankSequenceMetadataRetrieval.R. Este script permite a busca de sequências e metadados a partir de palavras-chave (*search_term*).

- d) As buscas no NCBIvirus também podem ser realizadas através de um script em R. Consulte o seguinte script para buscar sequências e metadados diretamente da base de dados 002R110 Sequence NCBIvirusSequenceMetadataRetrieval.R.

Salvando arquivos:

- a) As sequências biológicas deverão ser salvas em **arquivo no formato FASTA**. O arquivo original, obtido no banco de dados, deve ser nomeado com o padrão abaixo (sem acentos, espaços e caracteres incomuns, apenas *underline*):

Arquivo	gene_CTI_v01_Projeto_EspecificacaoArquivo.fas
Exemplo	env_01_v01_FeLV_Global_DadosOriginais.fas

- b) O nome acima contém diferentes identificadores:

gene: descreve qual o gene-alvo no arquivo. Se você estiver trabalhando com genoma completo, utilize o termo *CompleteGenome* como identificador, caso contrário, o nome do gene/segmento.

CTI: descreve o Código do Tipo de Informação, presente na seção Observações deste protocolo, e refere-se ao tipo de dado.

v01: refere-se à versão do arquivo. Qualquer modificação realizada no arquivo deve ser salva como uma nova versão através de números crescente a partir do 01. Essa abordagem permite facilmente recuperar versões anteriores do arquivo, que foram sendo modificadas ao longo do projeto.

Projeto: refere-se ao nome do projeto.

EspecificacaoArquivo: deve descrever, em poucas palavras, que tipo de dado existe no arquivo. Para dados obtidos de bancos de dados, você pode utilizar especificações do tipo “_DadosOriginaisGenBank”, por exemplo. Conforme o protocolo avança e novas modificações são realizadas neste arquivo, esta parte deve condizer com as novas informações (“_Alinhadas”, “_RecombinantesEliminadas”, etc).

- c) As sequências biológicas também devem, na medida do possível, ser obtidas apenas com o **número de acesso** (sem o subidentificador “.1”). Sequências advindas do GenBank devem permanecer com os nomes originais já que não há um mecanismo no banco de dados para baixar as sequências utilizando nomes específicos.

- d) As informações de metadados devem ser armazenadas em arquivo com a extensão xls. O máximo de informações sobre as amostras são requeridos, especialmente local de coleta (país, estado e cidade ou coordenadas geográficas), data de isolamento (quando possível, dia, mês e ano), espécie do hospedeiro e subtipo (no caso do FeLV). O arquivo original, obtido no banco de dados, deve ser nomeado com os rótulos abaixo (sem acentos, espaços e caracteres incomuns, apenas *underline*), seguindo o mesmo padrão que o arquivo de sequências biológicas (neste caso o CTI será sempre 00):

Arquivo **env_CTI_v01_FeLV_Global_MetadadosOriginal.xlsx**

Adição de sequências-referência:

- a) Adicione as sequências de referência clássicas de FeLV tanto no arquivo FASTA como no de metadados para contextualização e enraizamento da filogenia. Abaixo, encontra-se uma lista com as amostras de referência para as principais linhagens do vírus:

Subtipo/Linhagem	Acesso	Sequência
FeLV-A	AF052723	Genome/Rickard/1998
FeLV-B	J03448	env/Lambda-B1/1993
FeLV-C	M14331	env/Sarma/1993
FeLV-T	M89997	env/82K/1993
FeLV-E	AB635781	env/TG35-2/2013

- b) A sequência referência adicionada deve estar exatamente no tamanho (em pares de base, pb) e posição do gene/segmento o qual você deseja seu alinhamento final. Nesta etapa é importante pensar se a análise exige o genoma completo, um gene/segmento ou apenas uma porção codificante, por exemplo.
- c) Nos casos em que você desconhece as posições que delimitam cada gene dentro do seu genoma referência, é necessário consultar o GenBank para verificar estas posições. Para facilitar este processo, utilize o seguinte script para identificar as posições do genoma de uma referência dada [002R117_Sequence_DownloadingReferenceSequenceWithGenomeMap](#).

Controle de qualidade das sequências:

- a) No AliView, faça a filtragem inicial mantendo apenas as amostras que apresentarem cobertura adequada e correspondência na região gênica delimitada para a análise.

- b) Garanta o alinhamento correto das sequências com as sequências de referência, observe se os códons de início da referência e das amostras estão em concordância.
- c) Traduza a matriz para aminoácidos e remova as amostras que apresentarem códons de parada prematuros (X), alterações no quadro de leitura (frameshifts) ou mutações que comprometam a integridade da região codificante analisada.
- d) Sequências funcionais degeneradas, defeituosas ou que sugiram forte pseudogenização não funcional devem ser marcadas para exclusão do dataset final.
- e) É importante que todas as informações presentes no arquivo resultante desta análise sejam incluídas no arquivo de metadados.

Subtipagem das sequências:

- a) A identificação dos subgrupos de FeLV (A, B, C, T, E e D) baseia-se fortemente na triagem de sequências do gene *env* (envelope) e mapeamento de inserções/recombinações com elementos endógenos (enFeLV) e alterações genéticas associadas à emergência de variantes virais.
- b) Realize alinhamentos locais guiados contra o bloco de referências estabelecido para associar a identidade de sequência de cada amostra a um clado, subtipo ou variante específica.
- c) As informações de subgrupo mapeadas e clados atribuídos devem ser rigorosamente integradas de volta à planilha de metadados da rodada analítica.

Inclusão de colunas na tabela de metadados:

- a) Três novas colunas devem ser inseridas na tabela de metadados: coluna *Source*, *NewName* e coluna *FinalDataset*.
- b) A coluna *Source* deve indicar qual a origem da amostra: GenBank, NCBI Virus, laboratório, referência, publicação científica, etc.
- c) A coluna *NewName* deve conter um novo nome para cada uma das sequências do arquivo de metadados. Este nome vai ser criado com as informações já disponíveis no arquivo excel e garante que este novo identificador não conterá caracteres problemáticos como " " e/ou "(" e/ou ")" e/ou "?" e/ou "ñ" e/ou acentos.
- d) A coluna *FinalDataset* servirá para registrar as sequências que ficarão no *dataset* final e aquelas que serão retiradas (além do motivo da exclusão). Para preencher esta coluna, marque, inicialmente um "x" para todas as sequências e, em seguida:

- Selecione as sequências que não passaram nos filtros de qualidade definidos durante a etapa de controle de qualidade, na coluna *FinalDataset*, informe “qualidade”. Caso você queira ser mais específico, pode detalhar qual critério de qualidade garantiu a exclusão da sequência da análise final (“qualidade: *StopCodon*”, por exemplo).
 - Selecione as sequências que não pertencem ao subtipo, clado ou grupo que você deseja analisar e, na coluna *FinalDataset*, informe “subtipo” ou “clado” conforme apropriado.
 - A depender do objetivo do projeto, selecione as sequências que não pertencem à região geográfica desejada, ou fora das datas de coleta específicas, ou de hospedeiro indesejado e, na coluna *FinalDataset*, especifique o motivo da exclusão desse grupo de sequências.
 - *Datasets* obtidos a partir do NCBIvirus, ou do GenBank, podem conter amostras sequenciadas a partir de cultivo celular, clones ou mesmo com modificações induzidas. Para a maiores dos projetos de filogenética, estas sequências devem ser eliminadas do *dataset* final. Especifique o motivo da exclusão desse grupo de sequências.
 - Por último, caso necessário, exclua sequências que não possuem informação sobre data e local de coleta, ou mesmo sem informação sobre hospedeiro.
- e) Adicionalmente, se você precisa organizar a localidade das suas sequências por região, ou recodificar o nome dos países, a melhor prática é criar um nova coluna para estas informações. O script em R [002R068 Metadata IdentifyingGeoRegions.R](#) pode ajudar a identificar a região do mundo ao qual determinado país (especificado em uma coluna) pertence. Ainda, o script a seguir pode transformar as suas informações discretas (Brasil) em coordenadas geográficas [002R106 Metadata GeoCodificacaoCoordenadas.R](#).
- f) Adicionalmente, se você precisar modificar ou reorganizar o formato de datas (por exemplo, de YYYY-MM-DD para DD-MM-YYYY, ou de YYYY-MM-DD para o formato decimal, 2015.0213), utilize o script [002R094 Metadata ConvertingDates.R](#).

Modificando o nome das sequências:

- a) Para garantir que todas as sequências possuam identificadores adequados, esta etapa garante que as sequências sejam renomeadas.
- b) Na coluna *NewName* da tabela de metadados, construa a junção ideal para o seu dataset utilizando a fórmula do Excel:

= A2&" "&B2&" "&C2&" "&D2&" "&E2&" "&F2

- c) Através da fórmula acima, você junta as informações disponíveis nas colunas A – F, da linha 2, separando estas informações por “_”. Para FeLV, vamos padronizar o seguinte conjunto de informações:

Sequência **Acesso_Subtipo_Hospedeiro_País_Ano**

- d) Após estender a fórmula para todas as sequências da tabela, copie toda a coluna e, no mesmo lugar, cole a coluna como “Valor”. Isso garante que estas células deixem de ser fórmulas e passem a ser efetivamente o nome de que você criou.
- e) Verifique se nenhuma das sequências possui nome igual. Para isso, no excel, selecione a coluna com os novos nomes, vá até a aba Página Inicial > Formatação Condicional > Regras de Realce das células > Valores Duplicados > OK (mantenha o padrão). As células com nomes duplicados aparecerão em vermelho claro com letras em vermelho escuro. Observe se estas sequências realmente são amostras duplicadas, ou se é algum problema na nomenclatura. Caso sejam nomes duplicados, escolha uma das duas e, na coluna Final dataset, especifique “duplicada”.
- f) Evite nomes de sequências com “-”, “/”, “.”, espaços ou caracteres especiais.
- g) A seguir, crie uma tabela no excel. Na primeira coluna, cole o nome atual das suas sequências. Na coluna seguinte, cole as informações de NewName e nomeie estas colunas. Salve esta tabela no formato csv e utilize o script 002R037 Sequence RenamingSequencesFasta.R para mudar o nome das sequências no arquivo FASTA.

Selecionando as sequências para o *dataset* final pré-alinhamento:

- a) Na coluna *FinalDataset*, filtre apenas as sequências que passaram em todos os controles de qualidade (aquelas que possuem um “x”). Selecione a coluna com o nome destas sequências (em *NewName*), copie e cole esta coluna em um novo arquivo.
- b) Salve este arquivo (não deve conter nome de coluna) no formato csv.
- c) Este arquivo contém o nome das sequências que deverão entrar para o *dataset* final. Para fazer a seleção das sequências no arquivo FASTA, você deverá utilizar o script em R 002R008 Sequence ColetandoSequenciasArquivoFasta.R. O script gerará um arquivo FASTA que inclui apenas as sequências desejadas.

Alinhamento e edição das sequências:

- a) Para alinhar as sequências, utilize preferencialmente a ferramenta MAFFT (consultar Mafft_ProtocoloLabevir_v01). Para datasets pequenos, frequentemente observados em

estudos de FeLV, ou quando a região analisada permitir inspeção direta, o alinhamento também pode ser realizado e refinado manualmente no AliView.

- b) Abra o arquivo alinhado no Aliview e corte o alinhamento (início e fim) com base na sequência referência.
- c) Edite o alinhamento, eliminando colunas indesejáveis (ou mantendo-as, conforme o objetivo do projeto). Salve este arquivo como uma nova versão.
- d) Caso seja necessário eliminar alguma sequência, não esqueça de marcar, na aba FinalDataset, na tabela de metadados, o motivo da exclusão.

Identificação do tamanho das sequências:

- a) A próxima etapa consiste em identificar o tamanho das sequências do *dataset* e a proporção de adeninas (A), citosinas (C), G (guaninas), timinas (T), gaps (-) e bases ambíguas.
- b) Para isso, analise o seu arquivo FASTA (contendo as sequências biológicas) através do script R 002R013 Sequences CountingNucleotidesGapsAndAmbiguities. O script fornece uma tabela com a quantidade de cada caractere presente em cada sequência.
- c) As informações desta tabela devem ser adicionadas ao arquivo de metadados.
- d) Cuidado, este script leva em consideração os N (base indeterminada) para a contagem final de nucleotídeos. Assim, o melhor é criar uma fórmula de cálculo, no excel, para somar apenas as bases não ambíguas (A, C, G e T). Sequências que possuem um número reduzido de bases não ambíguas devem ser avaliadas criteriosamente e, quando necessário, eliminadas do dataset. Este ponto de corte é bastante importante e deve ser definido com base em critérios científicos compatíveis com os objetivos da análise.
- e) Sequências curtas (é importante definir previamente qual será o tamanho mínimo de sequência a ser considerado) e com excesso de ambiguidades (é importante definir o número máximo previamente) devem ser eliminadas e esta informação deve ser adicionada a tabela de metadados. e).
- f) Essa filtragem pode ser realizada através de um script do R, que calcula o comprimento da maior sequência da matriz e descarta automaticamente qualquer amostra com tamanho inferior a um limite previamente definido. Como regra geral, recomenda-se utilizar um ponto de corte correspondente a 75% do comprimento da maior sequência do alinhamento.
- g) Entretanto, o ponto de corte utilizado deve ser avaliado de acordo com os objetivos do estudo. Em casos excepcionais, sequências abaixo do limite estabelecido podem ser mantidas quando representarem grupos pouco representados no dataset. Por exemplo, para FeLV-

C e FeLV-E, a única sequência de referência disponível para determinada região gênica pode não atender ao critério mínimo de comprimento, mas ainda assim ser necessária para a contextualização filogenética da análise.

- h) Sempre que exceções aos critérios de tamanho forem realizadas, recomenda-se documentar esta decisão na tabela de metadados ou em arquivo complementar do projeto, descrevendo o motivo da manutenção da sequência no dataset final.

Identificação de sequências duplicadas:

- a) Muitas vezes, especialmente quando os dados são obtidos de diferentes plataformas, amostras podem estar representadas duas ou mais vezes em um *dataset*. Desta forma, é necessário identificar e excluir todas as sequências em repetição.
- b) Para esta etapa utilize o script em R 002R018 Sequence DeletngDuplicateSequences.R.
- c) Como resultado, o script fornece uma tabela em excel identificando os grupos de duplicação (as sequências com o mesmo número nesta coluna representam duplicações). Selecione a coluna e marque todos os valores repetidos em vermelho (Página Inicial > Formatação Condicional > Regras de Realce das células > Valores Duplicados > OK). Finalmente, filtre as linhas dessa coluna pela cor vermelha. Desta forma, você terá identificado todos os grupos que contém duplicatas.
- d) Analise se as sequências repetidas devem ser mantidas ou não e verifique quais sequências são excluídas pelo script R (observe as sequências com FALSE na coluna Representative_Sequence, essas serão excluídas).
- e) Antes da exclusão definitiva, recomenda-se verificar se as sequências duplicadas possuem diferenças relevantes nos metadados associados. Quando possível, mantenha a sequência com maior quantidade de informações disponíveis ou melhor qualidade de sequência.

Identificação de sequências recombinantes:

- a) Quando necessário, busque as sequências recombinantes no seu *dataset*.
- b) A principal ferramenta utilizada para identificar sequências recombinantes é o RDP5 (consultar RDP5_ProtocoloLabevir_v01). Ferramentas adicionais podem ser utilizadas para confirmação dos eventos de recombinação, conforme os objetivos da análise.
- c) Quando eventos de recombinação forem identificados, avalie a necessidade de exclusão destas sequências de acordo com os objetivos do estudo. Em análises filogenéticas convencionais, a remoção de sequências recombinantes é geralmente recomendada. Entretanto, em estudos

envolvendo a caracterização de subtipos recombinantes de FeLV, especialmente FeLV-B, estas sequências podem ser mantidas e analisadas separadamente.

- d) A exclusão pode ser realizada manualmente, quando houver poucas sequências, ou através do script 002R021_Sequence_ExcluindoSeqsArquivoFasta.R. Neste último caso, será necessário criar um arquivo csv contendo apenas os nomes das sequências a serem eliminadas (sem identificação de coluna).
- e) Não esqueça de identificar na tabela de metadados a exclusão destas sequências na coluna FinalDataset.

Reconstrução filogenética:

- a) Reconstrua uma filogenia de máxima verossimilhança para o arquivo FASTA.
- b) A principal ferramenta utilizada para reconstruir filogenias de máxima verossimilhança é o IQTree (consultar [IQTree_ProtocoloLabevir_v01](#)).

Visualização da árvore filogenética:

- a) Inicialmente, visualize a filogenia gerada na etapa anterior através da ferramenta FigTree (consultar [FigTree_ProtocoloLabevir_v01](#)) ou através da plataforma Microreact, utilizando o arquivo .treefile gerado pelo IQ-TREE juntamente com a tabela de metadados.
- b) Verifique a consistência dos agrupamentos observados, a posição das sequências de referência, os valores de suporte estatístico dos principais clados e a correspondência entre os agrupamentos filogenéticos e os metadados associados.
- c) Após a definição da árvore final, exporte a figura em formato vetorial (SVG ou PDF) para edição final e adequação ao formato de publicação, utilizando softwares como o Inkscape.

ANEXO I

CheckList para construção de *datasets* e análises em FeLV

Protocolo de análise desenvolvido por Dennis Maletich Junqueira, Taylice Leonel Batista e Bruna Bolina da Cunha e versão final revisada por Dennis Maletich Junqueira

Sumário:

Objetivo da análise	11
Fase 01 - Organização inicial do projeto	11
Fase 02 - Obtenção de dados	12
Fase 03 - Adição de sequências de referência	12
Fase 04 - Controle de qualidade das sequências	12
Fase 05 - Subtipagem das sequências	12
Fase 06 - Curadoria dos metadados	13
Fase 07 - Padronização dos metadados	13
Fase 08 - Renomeação das sequências	13
Fase 09 - Seleção do <i>dataset</i> final (pré-alinhamento)	13
Fase 10 - Alinhamento e edição	14
Fase 11 – Caracterização das sequências	14
Fase 12 - Identificação e remoção das duplicatas	14
Fase 13 - Identificação de recombinantes	14
Fase 14 - Reconstrução filogenética	15
Fase 15 - Visualização filogenética	15

Objetivo da análise:

Construir *datasets* de sequências de nucleotídeos confiáveis e reprodutíveis para análises filogenéticas, evolutivas e moleculares do Vírus da Leucemia Felina (FeLV).

Fase 01 – Organização inicial do projeto:

- () Criar pasta do projeto (sem espaços, acentos ou caracteres especiais)
- () Criar subpasta Analise_01
- () Definir nome padrão do projeto
- () Definir se a análise envolverá gene/segmento ou genoma completo

- () Definir a região genômica que será analisada.

Fase 02 – Obtenção de dados:

- () Baixar sequências das bases de dados (GenBank e/ou NCBI Virus).
- () Ao fazer o *download*, sempre que possível, nomear as sequências conforme o padrão:
Acesso_Subtipo_Hospedeiro_País_Ano
- () Manter nomes originais quando não for possível padronizar (ex: GenBank)
- () Salvar o arquivo FASTA com nome padronizado (CTI = 01):
gene_CTI_v01_Projeto_EspecificacaoArquivo.fas
- () Salvar o arquivo de metadados com nome padronizado (CTI = 00):
gene_CTI_v01_Projeto_MetadadosOriginal.xls
- () Verificar correspondência entre dados:
 - i) Todas as sequências do FASTA possuem entrada nos metadados
 - ii) Todas as entradas dos metadados possuem sequência correspondente no FASTA

Fase 03 – Adição de sequências de referência:

- () Adicionar sequência de referência apropriada ao seu *dataset*
- () Verificar correspondência entre a região analisada e as referências selecionadas
- () Adicionar referências dos subtipos FeLV-A, FeLV-B, FeLV-C, FeLV-D, FeLV-E e FeLV-T (quando disponíveis)
- () Atualizar metadados adicionando informações sobre as referências adicionadas.

Fase 04 – Controle de qualidade das sequências:

- () Abrir o alinhamento no AliView
- () Verificar cobertura adequada da região analisada
- () Confirmar alinhamento correto com as sequências de referência
- () Identificar códons de parada prematuros (X)
- () Identificar sequências degeneradas, defeituosas ou pseudogenizadas
- () Integrar resultados ao arquivo de metadados

Fase 05 – Subtipagem das sequências:

- () Realizar alinhamento contra o bloco de referências

- () Identificar subtipo viral (FeLV-A, FeLV-B, FeLV-C, FeLV-D, FeLV-E ou FeLV-T)
- () Avaliar agrupamentos filogenéticos preliminares
- () Avaliar possíveis eventos de recombinação envolvendo enFeLV
- () Integrar resultados ao arquivo de metadados.

Fase 06 – Curadoria dos metadados:

- () Criar coluna **Source** (origem da sequência)
- () Criar coluna **NewName**
- () Criar coluna **FinalDataset**
- () Marcar inicialmente todas as sequências com “x”
- () Identificar e marcar exclusões:
 - i) Qualidade inferior
 - ii) Subtipo ou clado não pertencente ao objetivo do estudo
 - iii) Metadados incompletos
 - iv) Cultivo/clones
 - v) Fora do escopo da sua análise (tempo/geografia/hospedeiro)

Fase 07 – Padronização dos metadados:

- () Padronizar nomes de países/localidades
- () Agrupar regiões geográficas (quando necessário)
- () Converter datas para o formato consistente
- () (Opcional) Converter datas para formato contínuo
- () (Opcional) Gerar coordenadas geográficas

Fase 08 – Renomeação das sequências:

- () Criar nomes padronizados na coluna NewName
- () Verificar duplicação de nomes
- () Corrigir nomes duplicados
- () Gerar tabela CSV (nome antigo → nome novo)
- () Rodar script de renomeação do FASTA

Fase 09 – Seleção do dataset final (pré-alinhamento):

- () Filtrar sequências com “x” na coluna FinalDataset
- () Exportar lista de nomes (sem cabeçalho)
- () Rodar script de coleta de sequências FASTA
- () Gerar tabela CSV (nome antigo → nome novo)
- () Gerar FASTA final pré-alinhamento

Fase 10 – Alinhamento e edição:

- () Rodar alinhamento no MAFFT ou AliView
- () Abrir alinhamento no AliView
- () Cortar início/fim com base na sequência referência
- () Revisar alinhamento manualmente
- () Salvar nova versão do arquivo

Fase 11 – Caracterização das sequências:

- () Rodar script de contagem de nucleotídeos/gaps/ambiguidades
- () Avaliar:
 - i) Quantidade de A, C, G e T
 - ii) Tamanho da sequência
 - iii) Quantidade de N
 - iv) Quantidade de gaps
- () Calcular número de bases não ambíguas (A+C+G+T)
- () Definir critérios mínimos de qualidade (tamanho e ambiguidade)
- () Integrar resultados ao arquivo de metadados

Fase 12 – Identificação e remoção das duplicatas:

- () Rodar script de identificação de duplicatas
- () Avaliar grupos de duplicação
- () Verificar coluna Representative_Sequence
- () Confirmar exclusões
- () Atualizar metadados

Fase 13 – Identificação de recombinantes:

- () Rodar análise no RDP5
- () Avaliar eventos recombinantes
- () Avaliar possíveis recombinações envolvendo enFeLV
- () Atualizar metadados

Fase 14 – Reconstrução filogenética:

- () Rodar IQ-TREE
- () Selecionar modelo evolutivo
- () Avaliar suporte (aLRT / bootstrap)
- () Gerar árvore final

Fase 15 – Visualização da filogenia:

- () Abrir árvore no FigTree
- () Verificar enraizamento
- () Conferir agrupamentos
- () Exportar figura final