

Vírus da Raiva

Protocolo de análise

Protocolo de análise desenvolvido por Dennis Maletich Junqueira, Luisa Rolim Krassuski e Simone de Oliveira Scherer e versão final revisada por Dennis Maletich Junqueira

Sumário:

Objetivo do protocolo	01
Observações	01
Pasta referente ao projeto	02
Obtenção dos dados	02
Salvando arquivos	03
Adição de sequências-referência	04
Controle de Qualidade das Sequências	05
Subtipagem das sequências	05
Inclusão de colunas na tabela de metadados	06
Modificando o nome das sequências	07
Selecionando as sequências para o dataset final pré-alinhamento	08
Identificação do tamanho das sequências	08
Identificação de sequências duplicadas	09
Identificação de sequências recombinantes	09
Reconstrução filogenética	10
Visualização da árvore filogenética	10
Anexo I (CheckList para construção de datasets e análises)	11

Objetivo do protocolo:

Descrever e padronizar o fluxo de análise de sequências biológicas do Vírus da Raiva, contemplando etapas de obtenção de dados, nomenclatura de sequências e arquivos, curadoria, alinhamento, reconstrução filogenética e análises adicionais.

Observações:

Neste documento, os seguintes termos são usados amplamente:

- a) Código do tipo de informação (CTI): para facilitar a identificação rápida do conteúdo dos arquivos manuseados nas análises, adota-se o seguinte padrão para a codificação de informação:
- 00 Arquivos relacionados aos metadados
 - 01 Arquivos relacionados às sequências biológicas
 - 02 Arquivos relacionados às filogenias
 - 03 Demais arquivos
- b) Formato FASTA: arquivo de sequências biológicas no formato .fas ou .fasta.
- c) Metadados: refere-se ao conjunto de informações que podem acompanhar a sequência biológica da amostra, como data de coleta, informações geográficas, hospedeiro, linhagem etc.
- d) Sequências biológicas: refere-se às sequências de nucleotídeos e/ou aminoácidos de genes, segmentos e/ou genomas.

Pasta referente ao projeto:

- a) Para iniciar um novo projeto, crie uma **pasta com o nome do Projeto**. Mantenha um nome simples, direto e evite acentos, espaços e caracteres incomuns.
- b) Dentro desta pasta, crie uma **subpasta chamada Analise_01**. Este procedimento é para garantir que, caso seja necessário recomençar o projeto, os dados iniciais não sejam perdidos. Não é incomum ter que recomençar um projeto seja pela adição de novas sequências, problemas de amostragem e/ou falta de sequências.

Obtenção dos dados:

- a) Os principais bancos de dados para a busca de sequências do vírus são:
- GenBank: <https://www.ncbi.nlm.nih.gov/genbank/>
 - NCBIvirus: <https://www.ncbi.nlm.nih.gov/labs/virus/vssi/#/>
- b) Nestes bancos de dados, você deve buscar as sequências biológicas e as informações de metadados.
- c) Enquanto outros bancos de dados permitem facilmente a obtenção de metadados e informações sobre as próprias sequências genéticas (como região gênica da sequência-alvo), o GenBank é muito menos permissível. Desta maneira, caso você necessite fazer buscas de sequências biológicas no GenBank, a melhor alternativa é utilizar o script a seguir

002R109_Sequence_GenbankSequenceMetadataRetrieval.R. Este script permite a busca de sequências e metadados a partir de palavras-chave (*search_term*).

- d) As buscas no NCBIvirus também podem ser realizadas através de um script em R. Consulte o seguinte script para buscar sequências e metadados diretamente da base de dados 002R110_Sequence_NCBIvirusSequenceMetadataRetrieval.R.

Salvando arquivos:

- a) As sequências biológicas deverão ser salvas em **arquivo no formato FASTA**. O arquivo original, obtido no banco de dados, deve ser nomeado com o padrão abaixo (sem acentos, espaços e caracteres incomuns, apenas *underline*):

Arquivo **gene_CTI_v01_Projeto_EspecificacaoArquivo.fas**

- b) O nome acima contém diferentes identificadores:

gene: descreve qual o gene-alvo no arquivo. Se você estiver trabalhando com genoma completo, utilize o termo *CompleteGenome* como identificador, caso contrário, o nome do gene/segmento.

CTI: descreve o Código do Tipo de Informação, presente na seção Observações deste protocolo, e refere-se ao tipo de dado.

v01: refere-se à versão do arquivo. Qualquer modificação realizada no arquivo deve ser salva como uma nova versão através de números crescente a partir do 01. Essa abordagem permite facilmente recuperar versões anteriores do arquivo, que foram sendo modificadas ao longo do projeto.

Projeto: refere-se ao nome do projeto.

EspecificacaoArquivo: deve descrever, em poucas palavras, que tipo de dado existe no arquivo. Para dados obtidos de bancos de dados, você pode utilizar especificações do tipo “_DadosOriginaisGenBank”, por exemplo. Conforme o protocolo avança e novas modificações são realizadas neste arquivo, esta parte deve condizer com as novas informações (“_Alinhadas”, “_RecombinantesEliminadas”, etc).

- c) As sequências biológicas também devem, na medida do possível, ser obtidas apenas com o **número de acesso** (sem o subidentificador “.1”). Sequências advindas do GenBank devem permanecer com os nomes originais já que não há um mecanismo no banco de dados para baixar as sequências utilizando nomes específicos.
- d) As informações de metadados devem ser armazenadas em arquivo com a extensão xls. O máximo de informações sobre as amostras são requeridos, especialmente local de coleta

(país, estado e cidade ou coordenadas geográficas), data de isolamento (quando possível, dia, mês e ano) e espécie do hospedeiro. O arquivo original, obtido no banco de dados, deve ser nomeado com os rótulos abaixo (sem acentos, espaços e caracteres incomuns, apenas *underline*), seguindo o mesmo padrão que o arquivo de sequências biológicas (neste caso o CTI será sempre 00):

Arquivo **gene_CTI_v01_Projeto_MetadadosOriginal.xls**

- e) As informações de metadados devem ser armazenadas em arquivo com a extensão xls. O máximo de informações sobre as amostras são requeridas, especialmente local de coleta (país, estado e cidade ou coordenadas geográficas), data de isolamento (quando possível, dia, mês e ano) e espécie do hospedeiro.

Adição de sequências-referência:

- a) A próxima etapa consiste em adicionar sequências de referência do vírus ou linhagem sob análise tanto no arquivo FASTA como no arquivo de metadados. Abaixo, encontra-se uma lista com as amostras de referência para as principais linhagens do vírus:

Subtipo/Linhagem	Acesso	Sequência
African-2	KC196743	Nigeria/Canislupusfamiliaris/2011
African-3	MG458307	SouthAfrica/Feliscatus/2000
Arctic-related	KM272192	China/Canislupusfamiliaris/2012
Asian	AB981663	Laos/Canislupus/04/11/2011
Bats	KM594041	Brazil/Desmodusrotundus/2013
Cosmopolitan	OR045942	Tanzania/Canislupusfamiliaris/2019
Indian-Sub	KF154999	UnitedKingdom/Canislupusfamiliaris/2008
RAC-SK	JQ685938	USA/Mephitis mephitis/2009
Vaccine RefSeq	NC_001542	NA_NA_NA

- b) A sequência referência adicionada deve estar exatamente no tamanho (em pares de base, pb) e posição do gene/segmento o qual você deseja seu alinhamento final. Nesta etapa é importante pensar se a análise exige o genoma completo, um gene/segmento ou apenas uma porção codificante, por exemplo.
- c) Nos casos em que você desconhece as posições que delimitam cada gene dentro do seu genoma referência, é necessário consultar o GenBank para verificar estas posições. Para

facilitar este processo, utilize o seguinte script para identificar as posições do genoma de uma referência dada 002R117_Sequence_DownloadingReferenceSequenceWithGenomeMap.

- d) Se o projeto requerer, adicione também sequências de clados específicos.

Controle de qualidade das sequências:

- a) Uma etapa importante na construção do *dataset* é o controle de qualidade das sequências inseridas, especialmente a verificação da presença de stop códons em alinhamentos com regiões codificantes.
- b) No Aliview, inicialmente, garanta que suas sequências estão no frame correto. Depois disso, traduza seu alinhamento e verifique a presença de stop códons (X) ao longo das sequências.
- c) As sequências que contiverem stop códons prematuros devem ser retiradas do alinhamento.
- d) É importante que todas as informações resultantes desta análise sejam incluídas no arquivo de metadados.

Subtipagem das sequências:

- a) Uma etapa importante na construção do *dataset* é a subtipagem das amostras. Para raiva, as sequências devem ser submetidas no RABVGLUE (<https://rabv-glue.cvr.gla.ac.uk/#/home>) ou MADDOG (<https://github.com/KathrynCampbell/MADDOG>). O MADDOG é o mais sugerido para datasets com muitas sequências.
- b) As informações sobre linhagem e clado obtidas no RABVGLUE ou MADDOG devem ser adicionadas ao arquivo de metadados.
- c) A tabela resultante desta análise, exportada em formato csv, indica, a linhagem, o país que já foi encontrado, o ano que foi vista pela primeira vez e o ano que foi vista pela última vez.
- d) A coluna ID é o nome da sequência, a coluna *lineage* refere-se a linhagem que aquela sequência se encaixa (*African-2, African-3, Arctic-related, Asian, Bats, Cosmopolitan, Indian-Sub RAC-SK e Vaccine*), a coluna *lineage_countries_seen* é o(s) país(es) que esta sequência foi vista, a coluna *lineage_first_seen* diz o ano que aquela sequência foi vista pela primeira vez e a *lineage_last_seen* diz o ano que aquela sequência foi vista pela última vez.
- e) É importante que todas as informações presentes no arquivo csv resultante desta análise sejam incluídas no arquivo de metadados da sequência (você pode fazer isso usando a função *cbind* do pacote *dplyr* no R).

Inclusão de colunas na tabela de metadados:

- a) Três novas colunas devem ser inseridas na tabela de metadados: coluna *Source*, *NewName* e coluna *FinalDataset*.
- b) A coluna *Source* deve indicar qual a origem da amostra: NCBIVirus, vacina, referência, etc.
- c) A coluna *NewName* deve conter um novo nome para cada uma das sequências do arquivo de metadados. Este nome vai ser criado com as informações já disponíveis no arquivo excel e garante que este novo identificador não conterá caracteres problemáticos como " " e/ou "(" e/ou ")" e/ou "?" e/ou "ñ" e/ou acentos.
- d) A coluna *FinalDataset* servirá para registrar as sequências que ficarão no *dataset* final e aquelas que serão retiradas (além do motivo da exclusão). Para preencher esta coluna, marque, inicialmente um "x" para todas as sequências e, em seguida:
 - Selecione as sequências que não passaram nos filtros de qualidade do Nextclade e, na coluna *FinalDataset*, informe "qualidade". Caso você queira ser mais específico, pode detalhar qual critério de qualidade garantiu a exclusão da sequência da análise final ("qualidade: StopCodon", por exemplo).
 - Selecione as sequências que não pertencem a linhagem que você deseja analisar e, na coluna *FinalDataset*, informe "linhagem".
 - A depender do objetivo do projeto, selecione as sequências que não pertencem à região geográfica desejada, ou fora das datas de coleta específicas, ou de hospedeiro indesejado e, na coluna *FinalDataset*, especifique o motivo da exclusão desse grupo de sequências.
 - *Datasets* obtidos a partir do NCBIvirus, ou do GenBank, podem conter amostras sequenciadas a partir de cultivo celular, clones ou mesmo com modificações induzidas. Para a maioria dos projetos de filogenética, estas sequências devem ser eliminadas do *dataset* final. Especifique o motivo da exclusão desse grupo de sequências.
 - Por último, caso necessário, exclua sequências que não possuem informação sobre data e local de coleta, ou mesmo sem informação sobre hospedeiro.
- e) Adicionalmente, se você precisa organizar a localidade das suas sequências por região, ou recodificar o nome dos países, a melhor prática é criar uma nova coluna para estas informações. O script em R [002R068_Metadata_IdentifyingGeoRegions.R](#) pode ajudar a identificar a região do mundo ao qual determinado país (especificado em uma coluna) pertence. Ainda, o script a seguir pode transformar as suas informações discretas (Brasil) em coordenadas geográficas [002R106_Metadata_GeoCodificacaoCoordenadas.R](#).

- f) Adicionalmente, se você precisar modificar ou reorganizar o formato de datas (por exemplo, de YYYY-MM-DD para DD-MM-YYYY, ou de YYYY-MM-DD para o formato decimal, 2015.0213), utilize o script [002R094_Metadata_ConvertingDates.R](#).

Modificando o nome das sequências:

- a) Para garantir que todas as sequências possuam identificadores adequados, esta etapa garante que as sequências sejam renomeadas.
- b) Na coluna *Newname* da sua tabela de metadados, crie a junção de metadados ideal para o seu projeto, utilizando a lógica abaixo:

= A2&"_"&B2&"_"&C2&"_"&D2&"_"

- c) Através da fórmula acima, você junta as informações disponíveis nas colunas A – F, da linha 2, separando estas informações por "_". Para raiva, vamos padronizar o seguinte conjunto de informações:

Sequência **Acesso_País_Hospedeiro_Ano**

- d) Após estender a fórmula para todas as sequências da tabela, copie toda a coluna e, no mesmo lugar, cole a coluna como "Valor". Isso garante que estas células deixem de ser fórmulas e passem a ser efetivamente o nome de que você criou.
- e) Verifique se nenhuma das sequências possui nome igual. Para isso, no excel, selecione a coluna com os novos nomes, vá até a aba Página Inicial > Formatação Condicional > Regras de Realce das células > Valores Duplicados > OK (mantenha o padrão). As células com nomes duplicados aparecerão em vermelho claro com letras em vermelho escuro. Observe se estas sequências realmente são amostras duplicadas, ou se é algum problema na nomenclatura. Caso sejam nomes duplicados, escolha uma das duas e, na coluna Final dataset, especifique "duplicada".
- f) Evite nomes de sequências com "-", "/", ou ".".
- g) A seguir, crie uma nova tabela no excel. Na primeira coluna, cole o nome atual das suas sequências. Na coluna seguinte, cole as informações de NewName e nomeie essas colunas. Salve esta tabela no formato csv e utilize o script [002R037_Sequence_RenamingSequencesFasta.R](#) para mudar o nome das sequências no arquivo FASTA.

Selecionando as sequências para o *dataset* final pré-alinhamento:

- a) Na coluna *FinalDataset*, filtre apenas as sequências que passaram em todos os controles de qualidade (aquelas que tem um “x”). Selecione a coluna com o nome destas sequências (em *NewName*), copie e cole esta coluna em um novo arquivo.
- b) Salve este arquivo (não deve conter nome de coluna) no formato csv.
- c) Este arquivo contém o nome das sequências que deverão entrar para o *dataset* final. Para fazer a seleção das sequências no arquivo FASTA, você deverá utilizar o script em R 002R008 Sequence ColetandoSequenciasArquivoFasta.R. O script gerará um arquivo FASTA que inclui apenas as sequências desejadas.

Alinhamento e edição das sequências:

- a) Para alinhar as sequências utilize a ferramenta mafft (consultar Mafft ProtocoloLabevir v01).
- b) Abra o arquivo alinhado no Aliview e corte o alinhamento (início e fim) com base na sequência referência.
- c) Edite o alinhamento, eliminando colunas indesejáveis (ou mantendo-as, conforme o objetivo do projeto). Salve este arquivo como uma nova versão.
- d) Caso seja necessário eliminar alguma sequência, não esqueça de marcar, na aba *FinalDataset*, na tabela de metadados, o motivo da exclusão.

Identificação do tamanho das sequências:

- a) A próxima etapa consiste em identificar o tamanho das sequências do *dataset* e a proporção de adeninas (A), citosinas (C), G (guaninas), timinas (T), gaps (-) e bases ambíguas.
- b) Para isso, analise o seu arquivo FASTA (contendo as sequências biológicas) através do script R 002R013 Sequences CountingNucleotidesGapsAndAmbiguities. O script fornece uma tabela com a quantidade de cada caractere nas sequências.
- c) As informações desta tabela devem ser adicionadas ao arquivo de metadados (você pode fazer isso usando a função `cbind` do pacote `dplyr` no R).
- d) Cuidado, este script leva em consideração os N (base indeterminada) para a contagem final de nucleotídeos. Assim, o melhor é criar uma fórmula de cálculo, no excel, para somar apenas as bases não ambíguas (A, C, G e T). Elimine sequências que possuem menos que um determinado número de bases não ambíguas (este ponto de corte é bastante importante, defina este número com base em questões científicas).

- e) Sequências curtas (é importante definir previamente qual será o tamanho mínimo de sequência a ser considerado) e com excesso de ambiguidades (é importante definir o número máximo previamente) devem ser eliminadas e esta informação deve ser adicionada a tabela de metadados.

Identificação de sequências duplicadas:

- a) Muitas vezes, especialmente quando os dados são obtidos de diferentes plataformas, amostras podem estar representadas duas ou mais vezes em um *dataset*. Desta forma, é necessário identificar e excluir todas as sequências em repetição.
- b) Para esta etapa utilize o script em R 002R018_Sequence_DeletingDuplicateSequences.R.
- c) Como resultado, o script fornece uma tabela em excel identificando os grupos de duplicação (as sequências com o mesmo número nesta coluna representam duplicações). Selecione a coluna e marque todos os valores repetidos em vermelho (Página Inicial > Formatação Condicional > Regras de Realce das células > Valores Duplicados > OK). Finalmente, filtre as linhas desta coluna pela cor vermelha. Desta forma, você terá identificado todos os grupos que contém duplicatas.
- d) Analise se as sequências repetidas devem ser mantidas ou não e verifique quais sequências são excluídas pelo script R (observe as sequências com FALSE na coluna Representative_Sequence, essas serão excluídas).

Identificação de sequências recombinantes:

- a) Quando necessário, busque as sequências recombinantes no seu *dataset*.
- b) A principal ferramenta utilizada para identificar sequências recombinantes é o RDP5 (consultar RDP5_ProtocoloLabevir_v01).
- c) Quando encontrar sequências recombinantes, o padrão é que estas sejam eliminadas do seu *dataset*. Você pode fazer isso manualmente, se forem poucas sequências, ou através do script 002R021_Sequence_ExcluindoSeqsArquivoFasta.R. Neste último caso, será necessário criar um arquivo csv apenas com os nomes das sequências a serem eliminadas (sem identificação de coluna).
- d) Não esqueça de identificar na tabela de metadados a exclusão destas sequências na coluna FinalDataset.

Reconstrução filogenética:

- a) Reconstrua uma filogenia de máxima verossimilhança para o arquivo FASTA.
- b) A principal ferramenta utilizada para reconstruir filogenias de máxima verossimilhança é o IQTree (consultar [IQTree ProtocoloLabevir_v01](#)).

Visualização da árvore filogenética:

- a) Inicialmente, visualize a filogenia gerada na etapa anterior através da ferramenta FigTree (consultar [FigTree ProtocoloLabevir_v01](#)) ou pelo site Microreact (consultar <https://microreact.org/>) onde você irá precisar do arquivo.treefile gerado e a sua tabela de metadados.

ANEXO I

CheckList para construção de *datasets* e análises para o Vírus da Raiva

Protocolo de análise desenvolvido por Dennis Maletich Junqueira, Luisa Rolim Krassuski e Simone de Oliveira Scherer e versão final revisada por Dennis Maletich Junqueira

Sumário:

Objetivo da análise	12
Fase 01 - Organização inicial do projeto	12
Fase 02 - Obtenção de dados	12
Fase 03 - Adição de sequências de referência	12
Fase 04 – Controle de qualidade das sequências	12
Fase 05 - Subtipagem das sequências	12
Fase 06 - Curadoria dos metadados	12
Fase 07 - Padronização dos metadados	13
Fase 08 - Renomeação das sequências	13
Fase 09 - Seleção do <i>dataset</i> final (pré-alinhamento)	13
Fase 10 - Alinhamento e edição	14
Fase 11 – Caracterização das sequências	14
Fase 12 - Identificação e remoção das duplicatas	14
Fase 13 - Remoção de sítios problemáticos	14
Fase 14 - Identificação de recombinantes	14
Fase 15 - Reconstrução filogenética	15

Objetivo da análise:

Construir *datasets* de sequências de nucleotídeos confiáveis e reprodutíveis para reconstrução filogenética de vírus.

Fase 01 – Organização inicial do projeto:

- () Criar pasta do projeto (sem espaços, acentos ou caracteres especiais)
- () Criar subpasta Analise_01
- () Definir nome padrão do projeto
- () Definir se a análise envolverá gene/segmento ou genoma completo

Fase 02 – Obtenção de dados:

- () Baixar sequências das bases de dados (GenBank e/ou NCBI Virus).
- () Ao fazer o *download*, sempre que possível, nomear as sequências conforme o padrão:
Acesso|País|Hospedeiro|DataDeColeta
- () Manter nomes originais quando não for possível padronizar (ex: GenBank)
- () Salvar o arquivo FASTA com nome padronizado (CTI = 01):
gene_CTI_v01_Projeto_EspecificacaoArquivo.fas
- () Salvar o arquivo de metadados com nome padronizado (CTI = 00):
gene_CTI_v01_Projeto_MetadadosOriginal.xls
- () Verificar correspondência entre dados:
 - i) Todas as sequências do FASTA possuem entrada nos metadados
 - ii) Todas as entradas dos metadados possuem sequência correspondente no FASTA

Fase 03 – Adição de sequências de referência:

- () Adicionar sequência de referência apropriada ao seu *dataset* (tamanho e região já cortadas na porção-alvo da análise)
- () Adicionar cepas vacinais (se aplicável)
- () Atualizar metadados adicionando informações sobre as referências adicionadas

Fase 04 – Controle de qualidade das sequências:

- () Verificar a presença de stop códons prematuros nas sequências pelo Aliview.

Fase 05 – Subtipagem das sequências:

- () Submeter sequências ao RABVGLUE e/ou MADDOG
- () Identificar linhagem/clado
- () Integrar resultados ao arquivo de metadados.

Fase 06 – Curadoria dos metadados:

- () Criar coluna **Source** (origem da sequência)

- () Criar coluna **NewName**
- () Criar coluna **FinalDataset**
- () Marcar inicialmente todas as sequências com “x”
- () Identificar e marcar exclusões:
 - i) Qualidade inferior
 - ii) Linhagem incorreta
 - iii) Metadados incompletos
 - iv) Cultivo/clones
 - v) Fora do escopo da sua análise (tempo/geografia/hospedeiro)

Fase 07 – Padronização dos metadados:

- () Padronizar nomes de países/localidades
- () Agrupar regiões geográficas (quando necessário)
- () Converter datas para o formato consistente
- () (Opcional) Converter datas para formato contínuo
- () (Opcional) Gerar coordenadas geográficas

Fase 08 – Renomeação das sequências:

- () Criar nomes padronizados na coluna NewName
- () Verificar duplicação de nomes
- () Corrigir nomes duplicados
- () Gerar tabela CSV (nome antigo → nome novo)
- () Rodar script de renomeação do FASTA

Fase 09 – Seleção do dataset final (pré-alinhamento):

- () Filtrar sequências com “x” na coluna FinalDataset
- () Exportar lista de nomes (sem cabeçalho)
- () Rodar script de coleta de sequências FASTA
- () Gerar tabela CSV (nome antigo → nome novo)
- () Gerar FASTA final pré-alinhamento

Fase 10 – Alinhamento e edição:

- () Rodar alinhamento no MAFFT
- () Abrir alinhamento no AliView
- () Cortar início/fim com base na sequência referência
- () Revisar alinhamento manualmente
- () Salvar nova versão do arquivo

Fase 11 – Caracterização das sequências:

- () Rodar script de contagem de nucleotídeos/gaps/ambiguidades
- () Avaliar:
 - i) Quantidade de A, C, G e T
 - ii) Tamanho da sequência
 - iii) Quantidade de N
 - iv) Quantidade de gaps
- () Calcular número de bases não ambíguas (A+C+G+T)
- () Definir critérios mínimos de qualidade (tamanho e ambiguidade)
- () Integrar resultados ao arquivo de metadados

Fase 12 – Identificação e remoção das duplicatas:

- () Rodar script de identificação de duplicatas
- () Avaliar grupos de duplicação
- () Verificar coluna Representative_Sequence
- () Confirmar exclusões
- () Atualizar metadados

Fase 13 – Remoção de sítios problemáticos:

- () Definir posições a serem removidas
- () Confirmar correspondência com alinhamento
- () Rodar script de remoção de posições
- () Gerar nova versão do alinhamento

Fase 14 – Identificação de recombinantes:

- () Rodar análise no RDP5
- () Avaliar eventos recombinantes
- () Remover sequências recombinantes
- () Atualizar metadados

Fase 15 – Reconstrução filogenética:

- () Rodar IQ-TREE
- () Selecionar modelo evolutivo
- () Avaliar suporte (aLRT / bootstrap)
- () Gerar árvore final

Fase 15 – Visualização da filogenia:

- () Abrir árvore no FigTree ou Microreact
- () Verificar enraizamento
- () Conferir agrupamentos
- () Exportar figura final