

Influenza

Protocolo de análise

Protocolo de análise desenvolvido por Dennis Maletich Junqueira, Gabriel Luís Müller, Gabriel Teixeira de Macedo e Rafaela Bianquin Mozzaquatro, versão final revisada por Dennis Maletich Junqueira

Sumário:

Objetivo do protocolo	01
Observações	01
Pasta referente ao projeto	02
Obtenção dos dados	02
Salvando arquivos	03
Adição de sequências-referência	04
Controle de qualidade das sequências	05
Subtipagem das sequências	06
Inclusão de colunas na tabela de metadados	07
Modificando o nome das sequências	08
Selecionando as sequências para o dataset final pré-alinhamento	09
Alinhamento e edição das sequências	09
Identificação do tamanho das sequências	09
Identificação de sequências duplicadas	10
Análise de mutações de interesse biológico	10
Reconstrução filogenética	11
Visualização da árvore filogenética	11
Anexo I (<i>CheckList</i> para construção de datasets e análises)	12

Objetivo do protocolo:

Descrever e padronizar o fluxo de análise de sequências biológicas do Influenza, contemplando etapas de obtenção de dados, nomenclatura de sequências e arquivos, curadoria, alinhamento, reconstrução filogenética e análises adicionais.

Observações:

Neste documento, os seguintes termos são usados amplamente:

- a) Código do tipo de informação (CTI): para facilitar a identificação rápida do conteúdo dos arquivos manuseados nas análises, adota-se o seguinte padrão para a codificação de informação:
- 00 Arquivos relacionados aos metadados
 - 01 Arquivos relacionados às sequências biológicas
 - 02 Arquivos relacionados às filogenias
 - 03 Demais arquivos
- b) Formato FASTA: arquivo de sequências biológicas no formato .fas ou .fasta.
- c) Metadados: refere-se ao conjunto de informações que podem acompanhar a sequência biológica da amostra, como data de coleta, informações geográficas, hospedeiro, linhagem etc.
- d) Sequências biológicas: refere-se às sequências de nucleotídeos e/ou aminoácidos de genes, segmentos e/ou genomas.
- e) Natureza segmentada do influenza: os vírus influenza apresentam genoma segmentado. Nos vírus influenza A e B, o genoma é composto por oito segmentos gênicos (PB2, PB1, PA, HA, NP, NA, MP e NS), enquanto nos vírus influenza C e D o genoma é composto por sete segmentos. Em virtude dessa característica, salvo indicação em contrário, cada segmento deverá ser tratado como uma unidade analítica independente ao longo deste protocolo, com arquivos de sequências, metadados, alinhamentos e reconstruções filogenéticas próprios.

Pasta referente ao projeto:

- a) Para iniciar um novo projeto, crie uma **pasta com o nome do Projeto**. Mantenha um nome simples, direto e evite acentos, espaços e caracteres incomuns.
- b) Dentro desta pasta, crie uma **subpasta chamada Analise_01**. Este procedimento é para garantir que, caso seja necessário recomeçar o projeto, os dados iniciais não sejam perdidos. Não é incomum ter que recomeçar um projeto seja pela adição de novas sequências, problemas de amostragem e/ou falta de sequências.

Obtenção dos dados:

- a) Os principais bancos de dados para a busca de sequências do vírus são:
- GenBank: <https://www.ncbi.nlm.nih.gov/genbank/>
 - NCBIvirus: <https://www.ncbi.nlm.nih.gov/labs/virus/vssi/#/>

- GISAID (EpiFlu): <https://gisaid.org/>

- b) Nestes bancos de dados, você deve buscar as sequências biológicas e as informações de metadados.
- c) Enquanto outros bancos de dados permitem facilmente a obtenção de metadados e informações sobre as próprias sequências genéticas (como região gênica da sequência-alvo), o GenBank é muito menos permissível. Desta maneira, caso você necessite fazer buscas de sequências biológicas no GenBank, a melhor alternativa é utilizar o script a seguir 002R109 Sequence GenbankSequenceMetadataRetrieval.R. Este script permite a busca de sequências e metadados a partir de palavras-chave (*search_term*).
- d) As buscas no NCBIvirus também podem ser realizadas através de um script em R. Consulte o seguinte script para buscar sequências e metadados diretamente da base de dados 002R110 Sequence NCBIvirusSequenceMetadataRetrieval.R.
- e) A utilização de sequências obtidas por meio do GISAID está condicionada à observância dos termos estabelecidos no *Database Access Agreement* (DAA), aceito durante o processo de cadastro na plataforma. Em publicações que utilizem sequências provenientes do GISAID, o GISAID deverá ser devidamente reconhecido. Para facilitar a atribuição e a rastreabilidade das sequências utilizadas, recomenda-se a criação de um EPI_SET contendo todas as sequências empregadas no estudo. O identificador do EPI_SET poderá ser mencionado na disponibilização dos dados da publicação e o GISAID citado nos agradecimentos. A criação de um EPI_SET pode ser feita pelo próprio site do GISAID.

Salvando arquivos:

- a) As sequências biológicas deverão ser salvas em **arquivo no formato FASTA**. O arquivo original, obtido no banco de dados, deve ser nomeado com o padrão abaixo (sem acentos, espaços e caracteres incomuns, apenas *underline*):

Arquivo **gene_CTI_v01_Projeto_EspecificacaoArquivo.fas**

- b) O nome acima contém diferentes identificadores:

gene: descreve qual o gene-alvo no arquivo. Se você estiver trabalhando com genoma completo, utilize o termo *CompleteGenome* como identificador, caso contrário, o nome do gene/segmento.

CTI: descreve o Código do Tipo de Informação, presente na seção Observações deste protocolo, e refere-se ao tipo de dado.

v01: refere-se à versão do arquivo. Qualquer modificação realizada no arquivo deve ser salva como uma nova versão através de números crescente a partir do 01. Essa abordagem permite facilmente recuperar versões anteriores do arquivo, que foram sendo modificadas ao longo do projeto.

Projeto: refere-se ao nome do projeto.

EspecificacaoArquivo: deve descrever, em poucas palavras, que tipo de dado existe no arquivo. Para dados obtidos de bancos de dados, você pode utilizar especificações do tipo “_DadosOriginaisGenBank”, por exemplo. Conforme o protocolo avança e novas modificações são realizadas neste arquivo, esta parte deve condizer com as novas informações (“_Alinhadas”, “_RecombinantesEliminadas”, etc).

- c) As sequências biológicas também devem, na medida do possível, ser obtidas apenas com o **número de acesso** (sem o subidentificador “.1”). Sequências advindas do GenBank devem permanecer com os nomes originais já que não há um mecanismo no banco de dados para baixar as sequências utilizando nomes específicos.
- d) As informações de metadados devem ser armazenadas em arquivo com a extensão xls. O máximo de informações sobre as amostras são requeridos, especialmente local de coleta (país, estado e cidade ou coordenadas geográficas), data de isolamento (quando possível, dia, mês e ano) e espécie do hospedeiro. O arquivo original, obtido no banco de dados, deve ser nomeado com os rótulos abaixo (sem acentos, espaços e caracteres incomuns, apenas *underline*), seguindo os mesmos padrões que o arquivo de sequências biológicas (neste caso o CTI será sempre 00):

Arquivo **gene_CTI_v01_Projeto_MetadadosOriginal.xls**

- e) As informações de metadados devem ser armazenadas em arquivo com a extensão xls. O máximo de informações sobre as amostras são requeridas, especialmente local de coleta (país, estado e cidade ou coordenadas geográficas), data de isolamento (quando possível, dia, mês e ano) e espécie do hospedeiro.

Adição de sequências-referência:

- a) A próxima etapa consiste em adicionar sequências de referência do vírus ou linhagem sob análise tanto no arquivo FASTA como no arquivo de metadados. Para influenza, as amostras de referência servem para enraizamento da filogenia. Abaixo, encontra-se uma lista com as amostras de referência para as principais linhagens do vírus:

Subtipo/Linhagem	Acesso	Sequência
H1N1pdm09	CY121680	A/California/07/2009
H3N2	EPI_ISL_69274	A/HongKong/1/1968
B/Victoria	CY018757	B/Victoria/02/1987
B/Yamagata	CY018765	B/Yamagata/16/1988
H5N1 (HPAI)	AF144305	A/goose/Guangdong/1/1996

- b) A sequência referência adicionada deve estar exatamente no tamanho (em pares de base, pb) e posição do gene/segmento o qual você deseja seu alinhamento final. Nesta etapa é importante pensar se a análise exige o genoma completo, um gene/segmento ou apenas uma porção codificante, por exemplo.
- c) Nos casos em que você desconhece as posições que delimitam cada gene dentro do seu genoma referência, é necessário consultar o GenBank para verificar estas posições. Para facilitar este processo, utilize o seguinte script para identificar as posições do genoma de uma referência dada [002R117 Sequence DownloadingReferenceSequenceWithGenomeMap](#).
- d) Além da sequência referência, é comum, nos *datasets* de influenza, adicionar as sequências utilizadas nas vacinas humanas ao longo dos anos. Não esqueça de adicionar as informações sobre estas sequências ao arquivo de metadados. As composições vacinais podem ser atualizadas periodicamente, embora nem todos os componentes sejam necessariamente substituídos a cada temporada. A lista de vírus recomendados para compor as vacinas contra influenza pode ser consultada em [WHO Recommendations for Influenza Vaccines](#). Para obter as sequências correspondentes, selecione a temporada e o hemisfério de interesse na página da OMS e identifique o nome do isolado recomendado (por exemplo, A/Missouri/11/2025). Em seguida, utilize o nome do isolado para realizar buscas em bancos de dados de sequências, como o GISAID ou o NCBI, e obtenha as sequências dos segmentos de interesse para inclusão no dataset. Para análises envolvendo vírus influenza H5N1 HPAI, recomenda-se a inclusão da cepa vacinal A/Hubei/1/2010 (GISAID EPI_ISL_96896), utilizada como vírus candidato vacinal para esse subtipo até o momento.
- e) Se o projeto requerer, adicione também sequências de clados específicos.

Controle de qualidade das sequências:

- a) Uma etapa importante na construção do *dataset* é o controle de qualidade das sequências inseridas. Para influenza, as sequências devem ser submetidas ao NextClade (<https://clades.nextstrain.org/>, consultar NextClade_ProtocoloLabevir).

- b) A tabela resultante desta análise, exportada em formato csv, indica, entre outras informações, possíveis problemas nas sequências analisadas. O campo `.status` geralmente traz valores como *good*, *mediocre* ou *bad*, dependendo da gravidade.
- c) A coluna `qc.mixedSites.status` avalia a presença de sítios mistos (posições com mais de um nucleotídeo detectado e sinal de mais de uma linhagem), a coluna `qc.privateMutations.status` refere-se a mutações privadas (mutações únicas), a coluna `qc.frameShifts.status` verifica a presença de *frameshifts* (mudanças no quadro de leitura) e a coluna `qc.stopCodons.status` avalia se há códons de parada prematuros na sequência.
- d) É importante que todas as informações presentes no arquivo csv resultante desta análise sejam incluídas no arquivo de metadados da sequência (você pode fazer isso usando a função `cbind` do pacote `dplyr` no R).

Subtipagem das sequências:

- a) Uma etapa importante na construção do dataset é a subtipagem das amostras. Para influenza, não existe uma ferramenta única capaz de classificar adequadamente todos os subtipos e linhagens, portanto, a abordagem utilizada irá depender dos seus dados e da pergunta de pesquisa. Abaixo seguem as principais ferramentas utilizadas para a subtipagem de sequências de influenza.
- b) NextClade (<https://clades.nextstrain.org/>, consultar NextClade_ProtocoloLabevir). Para subtipar sequências utilizando o NextClade, basta fazer o upload do seu arquivo de sequências a serem subtipadas. O site irá fornecer um dataset de referência para basear a sua subtipagem, mas você pode fazer isso manualmente selecionando “*Change reference dataset*”. Quando o dataset apropriado para o subtipo analisado for selecionado, os resultados serão gerados automaticamente pela plataforma.
- c) OctoFlu (Consultar Octoflu_ProtocoloLabevir). A subtipagem pelo OctoFlu é realizada através de linha de comando. Como o dataset de referência do OctoFlu é baseado em sequências suínas, é recomendável utilizá-lo para subtipagem de sequências suínas. Apesar disso ainda pode ser utilizado em sequências humanas.
- d) As informações de subtipo, linhagem e clado obtidas durante esta etapa devem ser incorporadas ao arquivo de metadados.

Inclusão de colunas na tabela de metadados:

- a) Três novas colunas devem ser inseridas na tabela de metadados: coluna *Source*, *NewName* e coluna *FinalDataset*.
- b) A coluna *Source* deve indicar qual a origem da amostra: GISAID, NCBIVirus, embrapa, vacina, referência, etc.
- c) A coluna *NewName* deve conter um novo nome para cada uma das sequências do arquivo de metadados. Este nome vai ser criado com as informações já disponíveis no arquivo excel e garante que este novo identificador não conterá caracteres problemáticos como “ ” e/ou “(” e/ou “)” e/ou “?” e/ou “ñ” e/ou acentos.
- d) A coluna *FinalDataset* servirá para registrar as sequências que ficarão no *dataset* final e aquelas que serão retiradas (além do motivo da exclusão). Para preencher esta coluna, marque, inicialmente um “x” para todas as sequências e, em seguida:
 - Selecione as sequências que não passaram nos filtros de qualidade do Nextclade e, na coluna *FinalDataset*, informe “qualidade”. Caso você queira ser mais específico, pode detalhar qual critério de qualidade garantiu a exclusão da sequência da análise final (“qualidade: StopCodon”, por exemplo).
 - Selecione as sequências que não pertencem a linhagem que você deseja analisar e, na coluna *FinalDataset*, informe “linhagem”.
 - A depender do objetivo do projeto, selecione as sequências que não pertencem à região geográfica desejada, ou fora das datas de coleta específicas, ou de hospedeiro indesejado e, na coluna *FinalDataset*, especifique o motivo da exclusão desse grupo de sequências.
 - *Datasets* obtidos a partir do NCBIVirus, ou do GenBank, podem conter amostras sequenciadas a partir de cultivo celular, clones ou mesmo com modificações induzidas. Para a maioria dos projetos de filogenética, estas sequências devem ser eliminadas do *dataset* final. Especifique o motivo da exclusão desse grupo de sequências.
 - Por último, caso necessário, exclua sequências que não possuem informação sobre data e local de coleta, ou mesmo sem informação sobre hospedeiro.
- e) Adicionalmente, se você precisa organizar a localidade das suas sequências por região, ou recodificar o nome dos países, a melhor prática é criar uma nova coluna para estas informações. O script em R 002R068 Metadata IdentifyingGeoRegions.R pode ajudar a identificar a região do mundo ao qual determinado país (especificado em uma coluna) pertence. Ainda, o script a seguir pode transformar as suas informações discretas (Brasil) em coordenadas geográficas 002R106 Metadata GeoCodificacaoCoordenadas.R.

- f) Adicionalmente, se você precisar modificar ou reorganizar o formato de datas (por exemplo, de YYYY-MM-DD para DD-MM-YYYY, ou de YYYY-MM-DD para o formato decimal, 2015.0213), utilize o script 002R094_Metadata_ConvertingDates.R.

Modificando o nome das sequências:

- a) Para garantir que todas as sequências possuam identificadores adequados, esta etapa garante que as sequências sejam renomeadas.
- b) Na coluna *Newname* da sua tabela de metadados, crie a junção de metadados ideal para o seu projeto, utilizando a lógica abaixo:

= A2&"_"&B2&"_"&C2&"_"&D2&"_"&E2&"_"&F2

- c) Através da fórmula acima, você junta as informações disponíveis nas colunas A – F, da linha 2, separando estas informações por "_". Para influenza, vamos padronizar o seguinte conjunto de informações:

Sequência **Origem|Segmento|Acesso|NomeIsolado|NomeDoVirus|Subtipo|Hospedeiro|
Pais|Data**

- d) Após estender a fórmula para todas as sequências da tabela, copie toda a coluna e, no mesmo lugar, cole a coluna como "Valor". Isso garante que estas células deixem de ser fórmulas e passem a ser efetivamente o nome de que você criou. Garanta que seus nomes não contenham espaço.
- e) Verifique se nenhuma das sequências possui nome igual. Para isso, no excel, selecione a coluna com os novos nomes, vá até a aba Página Inicial > Formatação Condicional > Regras de Realce das células > Valores Duplicados > OK (mantenha o padrão). As células com nomes duplicados aparecerão em vermelho claro com letras em vermelho escuro. Observe se estas sequências realmente são amostras duplicadas, ou se é algum problema na nomenclatura. Caso sejam nomes duplicados, escolha uma das duas e, na coluna Final dataset, especifique "duplicada".
- f) A seguir, crie uma nova tabela no excel. Na primeira coluna, cole o nome atual das suas sequências. Na coluna seguinte, cole as informações de NewName e nomeie estas colunas. Salve esta tabela no formato csv e utilize o script 002R037_Sequence_RenamingSequencesFasta.R para mudar o nome das sequências no arquivo FASTA.

Selecionando as sequências para o *dataset* final pré-alinhamento:

- a) Na coluna *FinalDataset*, filtre apenas as sequências que passaram em todos os controles de qualidade (aquelas que tem um “x”). Selecione a coluna com o nome destas sequências (em *NewName*), copie e cole esta coluna em um novo arquivo.
- b) Salve este arquivo (não deve conter nome de coluna) no formato csv.
- c) Este arquivo contém o nome das sequências que deverão entrar para o *dataset* final. Para fazer a seleção das sequências no arquivo FASTA, você deverá utilizar o script em R 002R008 Sequence ColetandoSequenciasArquivoFasta.R. O script gerará um arquivo FASTA que inclui apenas as sequências desejadas.

Alinhamento e edição das sequências:

- a) Para alinhar as sequências utilize a ferramenta mafft (consultar Mafft ProtocoloLabevir v01).
- b) Abra o arquivo alinhado no Aliview e corte o alinhamento (início e fim) com base na sequência referência.
- c) Edite o alinhamento, eliminando colunas indesejáveis (ou mantendo-as, conforme o objetivo do projeto). Salve este arquivo como uma nova versão.
- d) Caso seja necessário eliminar alguma sequência, não esqueça de marcar, na aba *FinalDataset*, na tabela de metadados, o motivo da exclusão.

Identificação do tamanho das sequências:

- a) A próxima etapa consiste em identificar o tamanho das sequências do *dataset* e a proporção de adeninas (A), citosinas (C), G (guaninas), timinas (T), gaps (-) e bases ambíguas.
- b) Para isso, analise o seu arquivo FASTA (contendo as sequências biológicas) através do script R 002R013 Sequences CountingNucleotidesGapsAndAmbiguities. O script fornece uma tabela com a quantidade de cada caractere nas sequências.
- c) As informações desta tabela devem ser adicionadas ao arquivo de metadados (você pode fazer isso usando a função `cbind` do pacote `dplyr` no R).
- d) Cuidado, este script leva em consideração os N (base indeterminada) para a contagem final de nucleotídeos. Assim, o melhor é criar uma fórmula de cálculo, no excel, para somar apenas as bases não ambíguas (A, C, G e T). Elimine sequências que possuem menos que um determinado número de bases não ambíguas (este ponto de corte é bastante importante, defina este número com base em questões científicas).

- e) Sequências curtas (é importante definir previamente qual será o tamanho mínimo de sequência a ser considerado) e com excesso de ambiguidades (é importante definir o número máximo previamente) devem ser eliminadas e esta informação deve ser adicionada a tabela de metadados.

Identificação de sequências duplicadas:

- a) Muitas vezes, especialmente quando os dados são obtidos de diferentes plataformas, amostras podem estar representadas duas ou mais vezes em um *dataset*. Desta forma, é necessário identificar e excluir todas as sequências em repetição.
- b) Para esta etapa utilize o script em R 002R018 Sequence DeletingDuplicateSequences.R.
- c) Como resultado, o script fornece uma tabela em excel identificando os grupos de duplicação (as sequências com o mesmo número nesta coluna representam duplicações). Selecione a coluna e marque todos os valores repetidos em vermelho (Página Inicial > Formatação Condicional > Regras de Realce das células > Valores Duplicados > OK). Finalmente, filtre as linhas dessa coluna pela cor vermelha. Desta forma, você terá identificado todos os grupos que contém duplicatas.
- d) Analise se as sequências repetidas devem ser mantidas ou não e verifique quais sequências são excluídas pelo script R (observe as sequências com FALSE na coluna Representative_Sequence, essas serão excluídas).

Análise de mutações de interesse biológico:

- a) Quando necessário, as sequências podem ser submetidas ao FluSurver (<https://flusurver.bii.a-star.edu.sg/>) para identificação e interpretação de mutações potencialmente relevantes do ponto de vista biológico. A ferramenta permite a anotação de substituições associadas, entre outros aspectos, à resistência antiviral, adaptação ao hospedeiro, alterações antigênicas, virulência e modificações em sítios de glicosilação. Para utilizar a ferramenta basta fazer upload do seu dataset de interesse e clicar em submit. Nota-se, que como output serão mostradas todas as mutações de interesse observadas no dataset, portanto, é necessário realizar uma filtragem daquelas mutações de interesse para o seu trabalho. Por exemplo, caso o seu trabalho busque identificar mutações de resistência à fármacos antivirais, você pode usar o sumário de inibidores de neuraminidase (https://cdn.who.int/media/docs/default-source/influenza/laboratory---network/quality-assurance/human-nai-marker-table_for-

[publication_final_20240918.pdf?sfvrsn=c6d153ec_3](#)) e usar somente as mutações adequadas para o seu subtipo.

Reconstrução filogenética:

- a) Reconstrua uma filogenia de máxima verossimilhança para o arquivo FASTA.
- b) A principal ferramenta utilizada para reconstruir filogenias de máxima verossimilhança é o IQTree (consultar [IQTree ProtocoloLabevir v01](#)).

Visualização da árvore filogenética:

- a) Inicialmente, visualize a filogenia gerada na etapa anterior através da ferramenta FigTree (consultar [FigTree ProtocoloLabevir v01](#)).

ANEXO I

CheckList para construção de *datasets* e análises de Influenza

Protocolo de análise desenvolvido por Dennis Maletich Junqueira, Gabriel Luís Müller, Gabriel Teixeira de Macedo e Rafaela Bianchini Mozzaquatro, versão final revisada por Dennis Maletich Junqueira

Sumário:

Objetivo da análise	12
Fase 01 - Organização inicial do projeto	12
Fase 02 - Obtenção de dados	13
Fase 03 - Adição de sequências de referência	13
Fase 04 - Controle de qualidade das sequências	13
Fase 05 - Subtipagem das sequências	13
Fase 06 - Curadoria dos metadados	14
Fase 07 - Padronização dos metadados	14
Fase 08 - Renomeação das sequências	14
Fase 09 - Seleção do <i>dataset</i> final (pré-alinhamento)	14
Fase 10 - Alinhamento e edição	15
Fase 11 – Caracterização das sequências	15
Fase 12 - Identificação e remoção das duplicatas	15
Fase 13 - Identificação de mutações de interesse	15
Fase 14 - Reconstrução filogenética	16
Fase 15 - Visualização da filogenia	16

Objetivo da análise:

Construir *datasets* de sequências de nucleotídeos confiáveis e reprodutíveis para reconstrução filogenética de vírus.

Fase 01 – Organização inicial do projeto:

- () Criar pasta do projeto (sem espaços, acentos ou caracteres especiais)
- () Criar subpasta Analise_01
- () Definir nome padrão do projeto
- () Definir se a análise envolverá gene/segmento ou genoma completo

Fase 02 – Obtenção de dados:

- () Baixar sequências das bases de dados (GenBank e/ou NCBI Virus e/ou GISAID).
- () Ao fazer o *download*, sempre que possível, nomear as sequências conforme o padrão:
Origem|Segmento|Acesso|NomeIsolado|NomeDoVirus|Subtipo|Hospedeiro|País|Data
- () Manter nomes originais quando não for possível padronizar (ex: GenBank)
- () Salvar o arquivo FASTA com nome padronizado (CTI = 01):
gene_CTI_v01_Projeto_EspecificacaoArquivo.fas
- () Salvar o arquivo de metadados com nome padronizado (CTI = 00):
gene_CTI_v01_Projeto_MetadadosOriginal.xls
- () Verificar correspondência entre dados:
 - i) Todas as sequências do FASTA possuem entrada nos metadados
 - ii) Todas as entradas dos metadados possuem sequência correspondente no FASTA

Fase 03 – Adição de sequências de referência:

- () Adicionar sequência de referência apropriada ao seu *dataset* (tamanho e região já cortadas na porção-alvo da análise)
- () Adicionar cepas vacinais (se aplicável)
- () Atualizar metadados adicionando informações sobre as referências adicionadas

Fase 04 – Controle de qualidade das sequências:

- () Submeter sequências ao Nextclade e Exportar tabela de resultados (.csv)
- () Avaliar as colunas:
 - i) qc.mixedSites.status mixed sites (*good, mediocre, bad*)
 - ii) qc.privateMutations.status (*good, mediocre, bad*)
 - iii) qc.frameShifts.status (*good, mediocre, bad*)
 - iv) qc.stopCodons.status (*good, mediocre, bad*)
- () Integrar resultados ao arquivo de metadados

Fase 05 – Subtipagem das sequências:

- () Submeter sequências ao NextClade e/ou OctoFlu
- () Identificar linhagem/clado
- () Integrar resultados ao arquivo de metadados.

Fase 06 – Curadoria dos metadados:

- () Criar coluna **Source** (origem da sequência)
- () Criar coluna **newName**
- () Criar coluna **FinalDataset**
- () Marcar inicialmente todas as sequências com “x”
- () Identificar e marcar exclusões:
 - i) Qualidade inferior
 - ii) Linhagem incorreta
 - iii) Metadados incompletos
 - iv) Cultivo/clones
 - v) Fora do escopo da sua análise (tempo/geografia/hospedeiro)

Fase 07 – Padronização dos metadados:

- () Padronizar nomes de países/localidades
- () Agrupar regiões geográficas (quando necessário)
- () Converter datas para o formato consistente
- () (Opcional) Converter datas para formato contínuo
- () (Opcional) Gerar coordenadas geográficas

Fase 08 – Renomeação das sequências:

- () Criar nomes padronizados na coluna newName
- () Verificar duplicação de nomes
- () Corrigir nomes duplicados
- () Gerar tabela CSV (nome antigo → nome novo)
- () Rodar script de renomeação do FASTA

Fase 09 – Seleção do dataset final (pré-alinhamento):

- () Filtrar sequências com “x” na coluna FinalDataset
- () Exportar lista de nomes (sem cabeçalho)
- () Rodar script de coleta de sequências FASTA
- () Gerar tabela CSV (nome antigo → nome novo)

- () Gerar FASTA final pré-alinhamento

Fase 10 – Alinhamento e edição:

- () Rodar alinhamento no MAFFT
- () Abrir alinhamento no AliView
- () Cortar início/fim com base na sequência referência
- () Revisar alinhamento manualmente
- () Salvar nova versão do arquivo

Fase 11 – Caracterização das sequências:

- () Rodar script de contagem de nucleotídeos/gaps/ambiguidades
- () Avaliar:
 - i) Quantidade de A, C, G e T
 - ii) Tamanho da sequência
 - iii) Quantidade de N
 - iv) Quantidade de gaps
- () Calcular número de bases não ambíguas (A+C+G+T)
- () Definir critérios mínimos de qualidade (tamanho e ambiguidade)
- () Integrar resultados ao arquivo de metadados

Fase 12 – Identificação e remoção das duplicatas:

- () Rodar script de identificação de duplicatas
- () Avaliar grupos de duplicação
- () Verificar coluna Representative_Sequence
- () Confirmar exclusões
- () Atualizar metadados

Fase 13 – Identificação de mutações de interesse:

- () Identificar mutações de interesse através do Flusurver
- () Filtrar apenas as sequências de interesse a partir do output geral

Fase 14 – Reconstrução filogenética:

- () Rodar IQ-TREE
- () Selecionar modelo evolutivo
- () Avaliar suporte (aLRT / bootstrap)
- () Gerar árvore final

Fase 15 – Visualização da filogenia:

- () Abrir árvore no FigTree
- () Verificar enraizamento
- () Conferir agrupamentos
- () Exportar figura final