RDP5

Protocolo de análise da ferramenta

Protocolo de análise desenvolvido por Dennis Maletich Junqueira e Sandro Rodrigo Martins Sobrinho e versão final revisada por Dennis Maletich Junqueira

Sumário:

Objetivo da análise 01
Instalação 01
Observações 02
Configurando a Análise: 02
Running 05
Resultados gerais 05
Analisando os resultados das Filogenias 06
Analisando os resultados das Tabelas 09
Analisando os resultados dos Gráficos dos Pontos de Recombinação 10
Análises Adicionais – Plot de Distribuição de *Breakpoints* 12
Análises Adicionais – Plot de posição do genoma e os *breakpoints* 12
Análises Adicionais – Filogenias I 13
Análises Adicionais – Filogenias II 13
Referências 14
Anexo I (*CheckList* de Validação de Eventos de Recombinação 15

Objetivo da análise:

Identificar sequências recombinantes, seu(s) parental(is) major(s) e minor(s) e os respectivos pontos de recombinação.

Instalação:

a) A ferramenta roda bem em Windows 95/98/NT/VISTA/7/8 e pode ou não rodar bem em Windows 10. Não existem versões para outros sistemas operacionais, de forma que para usuários de Mac é recomendado o uso do emulador 'PlayOnMac', e para usuários de sistema Linux, recomenda-se o emulador 'Wine';

b) Este protocolo foi desenvolvido para a versão mais recente do programa RDP, o RDP5 v5.84.

c) Para realizar o download e instalação do programa, basta clicar no link e rodar o arquivo executável: https://web.cbio.uct.ac.za/~darren/RDP5.84Setup.exe

Observações:

Para rodar o programa você precisará dos seguintes arquivos:

a) Alinhamento das sequências no formato fasta. É importante que este alinhamento tenha sido gerado com rigor, especialmente em casos de sequências muito divergentes. Nestes casos, se aconselha fazer o alinhamento por códons em programas como Prank ou mesmo mafft L-ins-i (e uma análise no de códons no Aliview). Além disso, também é aconselhável a realização de um mascaramento para regiões muito variáveis. É possível fazer isso selecionando os sítios que se quer mascarar e apertando a tecla 'n' no Aliview.

Configurando a Análise:

a) Após abrir a ferramenta, selecione *Open* e carregue o arquivo .fas contendo sequências já alinhadas. Lembre-se que o número de sequências no dataset pode ser importante para definir a variabilidade possível para aquele gene/organismo, da mesma forma que o tamanho das sequências. Para *datasets* pouco variáveis, aumentar os comprimentos das sequências que estão sendo examinadas pode aumentar o número de locais variáveis utilizáveis para detecção de recombinação.

b) Selecione *Options* para definir as principais características da análise de recombinação.

c) Na aba *General*, marque a opção para o tipo de genoma (linear/circular).

d) Defina uma sequência referência em *General* > *Reference sequence*. Apesar de esta escolha não alterar a detecção estatística dos eventos de recombinação, ela pode influenciar como os resultados serão exibidos. Sugere-se escolher a sequência que contemple a maior parte do alinhamento, bem anotada, completa, sem Ns e de boa qualidade. Mais importante, tentar escolher uma sequência não-recombinante.

e) Passe para *Data Processing Options* e garanta que as três primeiras opções estejam marcadas (*Require topological evidence*, *Polish Breakpoints*, e *Check Alignment Consistency*). Caso a última opção *Disentangle Overlapping Events* esteja solucionada, o programa tentará garantir que a hipótese de recombinação não invoque recombinação entre sequências recombinantes com mosaicos similares. Esta opção funciona bem quando a recombinação no *dataset* é relativamente esparsa e há evidência de *hotspots*. O manual aconselha que, inicialmente,

esta opção seja marcada e, caso você observe que a análise travou, reinicie o processo com a opção desmarcada.

f) Passe para as opções de *Analyse sequences using* e selecione os métodos utilizados para detectar recombinação. O manual incentiva o usuário a selecionar todos os métodos default (RDP, GENCONV, e MAXCHI). No entanto, caso você esteja analisando um pequeno *dataset* (<50 sequências) e/ou o tempo de análise não seja um problema, é aconselhável selecionar também CHIMAERA, BOOTSCAN/RECSCAN, SISCAN e 3SEQ.

g) É importante ressaltar que alguns métodos não são independentes (compartilham o mesmo tipo de sinal estatístico) e outros tem um desempenho bem diferente dependendo do cenário (divergência moderada, genoma longo, estrutura de clados). Desta forma, no momento de escolher os métodos de recombinação, ou mesmo o número de métodos com resultados concordantes, busque avaliar se as concordâncias não estão "presas" a uma mesma lógica de análise. Assim, os métodos podem ser agrupados em:

- Métodos baseados em similaridade/distância: Detectam mudanças abruptas na distância genética entre a recombinante e outras sequências ao longo alinhamento. A pergunta central deste método é "a sequência muda sua posição na filogenia ao longo do genoma?". Métodos: BOOTSCAN, SISCAN, RDP e 3Seq (parcialmente). São muito sensíveis, bons para recombinação recente e bons para fragmentos grandes. No entanto, são sensíveis à estrutura populacional, afetados pela heterogeneidade de taxa e falsos positivos com divergência moderada.

- Métodos baseados em incompatibilidade de sítios: Recombinação gera padrões de substituição incompatíveis com evolução puramente clonal. São baseados em distribuição de polimorfismos, estatísticas tipo qui-quadrado e clustering de substituições. A pergunta central deste método é "a distribuição de mutações muda abruptamente entre regiões?". Métodos: MAXCHI, CHIMAERA e GENCONV. São bons para detectar fragmentos intermediários e detectam mosaicos discretos. No entanto, são sensíveis a alinhamentos ruins, confundem homoplasia com recombinação e são sensíveis a densidade de SNPs.

- Métodos explicitamente filogenéticos: Recombinação causa incongruência topológica entre árvores reconstruídas para diferentes regiões. A pergunta central deste método é "a posição da sequência muda entre árvores independentes?". Métodos do RDP: não é um método automático primário, pois se trata de uma etapa de validação (filogenias *outside* e *inside*). É mais biologicamente interpretável, menos sensível a ruído local e melhor para

publicação. No entanto, precisa de sinal filogenético forte e pode falhar com recombinação muito recente.

- Métodos baseados em modelos probabilísticos exatos: Testam se o padrão observado é mais provável sob modelo clonal ou modelo mosaico. Métodos: 3Seq (calcula probabilidade exata de que uma sequência seja combinação de duas outras). É conservador e menos afetado por ruído topológico. No entanto, é menos sensível a eventos complexos e pode perder recombinação antiga.

h) Preste atenção ao BOOTSCAN e ao SISCAN, existem duas caixas separadas na frente deles. Por padrão, esses dois verificarão automaticamente os sinais de recombinação detectados por outros métodos, se clicarmos na primeira caixa, isso forçará seu uso para explorar novos sinais, mas esteja avisado que aumentará drasticamente o tempo de análise.

i) O método LARD também é usado apenas para verificar sinais e é adequado para conjuntos de dados muito pequenos (menos de 20 sequências). Os métodos RDP, GENCONV, MAXCHI, 3SEQ e CHIMAERA serão automaticamente usados para checar sinais de recombinação detectados por outros métodos independentes de estarem selecionados ou não.

j) Nas abas descrevendo o funcionamento de cada um dos métodos a única opção que deve ser trocado, caso necessário, é o *Window* e *step sizes*. O *window size* ótimo variará de método para método e de *dataset* para *dataset*. É importante notar que enquanto RDP, 3SEQ, GENECONV, MAXCHI e CHIMAERA apenas examinam posições com variação de nucleotídeos em tripletos de sequências amostradas aleatoriamente do alinhamento, BOOTSCAN, SISCAN, e LARD examinam toda variação e regiões conservadas. Note também que CHIMAERA e MAXCHI *Windows* devem ser aproximadamente o dobro da janela do RDP e que as janelas de SISCAN, BOOTSCAN devem ser aproximadamente do mesmo tamanho. Idealmente, o tamanho das janelas devem ser o menor possível para garantir que eventos envolvendo mudanças de pequenos fragmentos sejam detectáveis na sequência mais divergente no *dataset*.

k) O tamanho ótimo da janela para detectar eventos de recombinação envolvendo uma troca de 200 pb é 200 para BOOTSCAN e SISCAN e varia para os outros métodos dependendo do número de diferença de nucleotídeos entre a sequência parental e a região recombinante. O MAXCHI e CHIMAERA podem ser rodados utilizando uma janela variável que, respectivamente, ficará maior e menor com menor e maior graus de divergência das sequências parentais. Embora as configurações de tamanho de janela possam ter um impacto substancial na hipótese de recombinação preliminar formulada durante o estágio de

análise de triagem de sinal de recombinação automatizada, a fase subsequente (e necessária) de testes manuais e resultados de análise de refinamento devem neutralizar qualquer "tendência de configuração" introduzido.

Running:

a) Se você apertar o botão *Run* e selecionar *Do a full exploratory recombination scan using all methods…* o programa iniciará uma análise exploratória automática. Há duas fases na análise automática: a) detecção de sinais de recombinação no alinhamento, b) inferência do número e características dos eventos únicos de recombinação. A partir desta análise, é possível realizar uma análise de hipóteses e refinamento do processo de análise da recombinação.

Resultados gerais:

a) O resultado de recombinação do RDP está principalmente representado por retângulos coloridos no canto direito, abaixo.

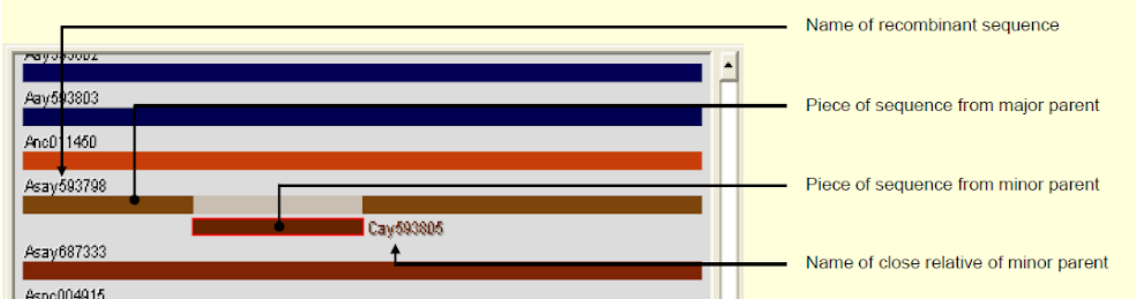

b) É muito provável que, a menos que a execução inicial automatizada de RDP4 indique apenas algumas sequências recombinantes (<20% das sequências no conjunto de dados são recombinantes), <u>o programa terá cometido alguns erros ao interpretar os padrões de recombinação que detectou</u>. Como os erros no início da análise provavelmente serão mais sérios do que os erros no final, você deve sempre iniciar o processo de refinamento com o evento de recombinação que o programa caracterizou primeiro.

c) Assim, depois de todas as análises realizadas, é importante que você diga ao programa que está, pelo menos provisoriamente, feliz com a forma como o evento atual foi caracterizado. Para isso, clique com o botão direito na caixa colorida que representa a recombinação, na janela das barras coloridas e selecione a opção *Accept this event.* Uma borda vermelha será desenhada ao redor da caixa colorida (e todas as outras representando o mesmo evento) e isso dirá ao programa que em todas as análises subsequentes você está satisfeito com a caracterização deste evento. Se não estiver satisfeito com a forma como você ou o programa

caracterizaram o evento, você pode optar por deixar o evento sem aceitação ou pode selecionar a opção "Rejeitar todos os semelhantes". Se os eventos forem aceitos ou rejeitados, o programa os ignorará quando você estiver navegando pelos eventos restantes que precisam ser verificados. Você também pode aceitar a recombinação em *Overview.* Um checklist incluindo todas as análises, incluindo diferentes programas, para decidir sobre os eventos de recombinação está disponível (Anexo I) e pode ajudar você na decisão de aceitar ou rejeitar um evento. No entanto, é recomendado que a análise siga os passos deste protocolo: primeiro a análise das filogenias, depois as tabelas e finalmente os gráficos de recombinação.

d) Outra forma de aceitar/rejeitar os eventos de recombinação é através das filogenias. Ao clicar com o botão direito em uma das sequências da filogenia, é possível marcar a sequência como "Recombinante" ou "Não recombinante", ou ainda ajustar os parentais. Isso modifica o status do evento no painel principal. Através dessa ação, você estará informado ao RDP se a incongruência filogenética observada é biologicamente plausível e consistente com recombinação ou se o evento é um artefato.

f) Para reanalisar os dados levando em consideração suas modificações, pressione o botão *Re-scan* abaixo da janela das barras coloridas.

g) Você pode salvar o alinhamento excluindo as sequências recombinantes através de *Save* > *Save alignment with recombinant sequences removed*. O dataset gerado não fica alinhado da mesma forma e, portanto, será necessário copiar o nome das sequências nesse arquivo e através do =PROCV procurar as sequências recombinantes (que foram excluídas) e, a partir daí jogar os dados no R (script: excluindoSeqsArquivoFasta) para gerar o alinhamento correto.

h) Salve sua análise regularmente. Selecione *Save* > *Save recombination results to a .rdp Project file*, localizado no topo da janela do programa. Se desejar um resumo tabulado dos resultados opte por salvar os dados no formato ".csv". Este formato permitirá que você abra os resultados em programas de planilhas como o Microsoft Excel e o LibreOffice Calc. Observe, entretanto, que o RDP4 não será capaz de recarregar sua análise de um arquivo ".csv".

Analisando os resultados das filogenias:

a) Na tabela exibida à direita, acima, na aba *Overview*, clique no primeiro evento de recombinação detectado.

b) A melhor ferramenta disponível no RDP para avaliar se a sequência recombinante foi identificada corretamente é desenhar e comparar duas árvores filogenéticas, uma construída a partir da parte do alinhamento entre os pontos de recombinação inferidos e a outra incluindo o alinhamento completo. Você pode ver essas árvores lado a lado se você pressionar o botão *Trees* no painel de comando na parte superior da tela. Se você preferir uma árvore com bootstrap, de máxima verossimilhança ou uma árvore Bayesiana, você pode alterar o tipo de árvore que é exibido (a) movendo o cursor do mouse sobre uma das árvores, (b) pressionando o botão direito do mouse, (c) selecionando "alterar tipo de árvore".

c) Nestas janelas, a lógica é a seguinte: na janela à esquerda, o programa mostra a filogenia reconstruída a partir do possível segmento ***major*** (esse representaria a **porção não recombinante**), enquanto a janela à direita mostra a filogenia reconstruída a partir do possível segmento ***minor*** (esse representaria a **porção recombinante**).

d) Comparando a localização da sequência recombinante, das sequências parentais e daquelas que possuem o mesmo padrão de recombinação, o programa avalia em qual clado estava a sequência e para onde "mudou" na árvore que mostra apenas a porção recombinante. A partir dessa mudança de posição, o programa consegue entender quem é o possível major e minor.

e) O RDP4 permite que você marque sequências específicas nas árvores que exibe. Isso pode ser muito útil para rastrear o "movimento" de sequências específicas entre os clados de árvores diferentes. Você pode marcar uma sequência movendo o ponteiro do mouse sobre o nome da sequência na árvore e pressionando o botão esquerdo do mouse. A mesma sequência é então marcada em todas as árvores. Você pode limpar as marcações em *Clear Colour* ao clicar o botão esquerdo do mouse sobre a sequência.

f) Quando a sequência recombinante e as sequências com o mesmo padrão estão no mesmo clado pode ser que o ancestral dessas sequências é que seja o recombinante e não as próprias sequências. No entanto, se essas sequências não estão se movendo juntas nas duas filogenias construídas isso pode significar que o RDP5 está realizando um "over-grouping" com estas sequências. Nesses casos, uma alternativa seria retirar as sequências mais próximas do recombinante (o clado onde ele está, exceto ele) e rodar a análise de novo. Se o evento desaparecer, era muito provavelmente um efeito de estrutura / proximidade. Além disso, pode ser interessante olhar para todas as sequências que estão nesse clado que está "andando junto" e verificar o padrão de recombinação delas. Outra análise possível é, no TreeOrder Scan (002R114_Recombinacao_TreeOrderScan_v2), identificar essas

sequências e verificar se todas elas andam juntas – isso pode significar que o genótipo/subtipo surgiu como um recombinante e o padrão se mantém.

g) Nessa etapa você deve olhar se, na árvore *outside*, a sequência recombinante agrupa com o *major parent*. Na árvore *inside*, você deve analisar se a sequência muda de posição e agrupa com o *minor parent*. Caso estes eventos não ocorram de forma clara, temos um alerta. Aqui, é importante chamar a atenção para o método utilizado pelo RDP para reconstruir as filogenias: neighbor-joining (sem suporte de nó). Em virtude disso, a melhor prática é reconstruir as mesmas filogenia através de máxima verossimilhança e olhar para um método de suporte dos ramos.

h) Caso você queira fazer um simplot rápido comparando uma sequência recombinante com outra, basta clicar com o botão direito na sequência que você quer comparar com a sequência recombinante em análise e escolher "Recheck the plot with NAME as the recombinant". A linha azul representará porções que são similares para as duas sequências.

i) Quando existem várias sequências recombinantes no mesmo evento, na filogenia, aperte com o botão direito em cima da sequência desejada e escolha "Go to". Automaticamente, aparecerá o diagrama de recombinação desta sequência. Selecione a região que aparece como recombinação e veja se a posição da recombinação é semelhante ao outros casos das sequências com padrão similar. Caso não esteja, é melhor arrumar para que todas fiquem com o breakpoint igual.

j) Não esqueça, a análise da filogenia é apenas uma das etapas para decisão sobre os eventos de recombinação listados pelo RDP5. Antes de decidir sobre a consistência biológica do evento, consulte todos os resultados (nas próximas seções).

k) Tenha muito cuidado ao decidir mudar a escolha do recombinante que o programa fez, pois há muitos fatores que podem complicar seriamente a identificação de sequências recombinantes usando árvores filogenéticas. Como RDP5 usa três sequências por vez para identificar sinais de recombinação, há uma probabilidade muito alta de que, dada recombinação suficiente em um conjunto de dados, duas ou mesmo três das sequências usadas para detectar um sinal de recombinação serão recombinantes (ou seja, como quando as sequências recombinantes passaram por outros processos de recombinação). Embora este seja um problema particularmente sério se duas ou três das sequências recombinantes no tripleto de sequência tiverem pontos de interrupção próximos um do outro, pode até ser um problema se os pontos

de interrupção estiverem em partes completamente diferentes da sequência. Se os pontos de interrupção em duas ou três das sequências em um tripleto estiverem próximos, o programa possivelmente irá inferir um evento de recombinação com dois pontos de interrupção, cada um proveniente de uma sequência recombinante diferente no trio. Como isso afetará as árvores construídas quando esses pontos de interrupção são usados para particionar o alinhamento, varia de caso para caso, mas pode influenciar a eficácia com que as árvores podem ser usadas para julgar a precisão da identificação da sequência recombinante. Mesmo quando os pontos de interrupção corretos são usados para particionar as sequências, o fato de que uma ou ambas as sequências parentais inferidas também são recombinantes pode afetar sua colocação dentro das árvores tornando muito difícil identificar qual sequência é recombinante.

I) Finalmente, mesmo se ambas as sequências parentais inferidas forem não recombinantes, o conjunto de dados pode conter qualquer número de outras sequências recombinantes, qualquer uma das quais pode confundir a identificação de uma sequência recombinante com base na avaliação de qual sequência "se moveu" mais entre as árvores. Se você não estiver satisfeito com a sequência recombinante identificada pelo RDP5, lembre-se sempre de que o programa usou a abordagem filogenética junto com uma bateria de outros testes e, por algum motivo (talvez muito bom), propôs sua escolha particular. Além disso, se você acha que o programa cometeu um erro, certifique-se de entender o que as árvores estão dizendo. Lembre-se de que, embora as árvores sejam apresentadas com uma raiz de ponto médio para fins de clareza, todas elas não têm raízes e, portanto, a direção da evolução pode não ser imediatamente clara. Sua maior chance de se sair melhor do que o programa na identificação de verdadeiros recombinantes é quando o programa identificou dois candidatos a recombinantes muito próximos (ele lhe dirá quais são).

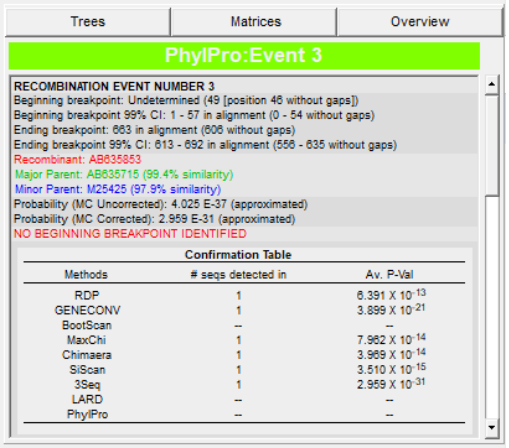

Analisando os resultados das Tabelas:

a) Verifique as informações disponibilizadas na aba *Recombination Info*, localizada no alto, à direita.

b) Nesta aba, você encontrará os breakpoints possíveis, os nomes das sequências envolvidas na recombinação, a probabilidade de que o sinal aparente de recombinação tenha surgido por mutação convergente (sob seleção neutra) ao invés de recombinação (MC uncorrected), o número de sequências no dataset que carregam sinais de recombinação similares e um gráfico de barras mostrando a evidência usada pelo programa para identificar o recombinante. Os P-values na tabela exibida nesta janela são também relativos à probabilidade de o processo de recombinação ter ocorrido (pode ocorrer grande diferença entre os valores de p devido à abordagem de cada um dos métodos).

c) Abaixo da tabela, existem gráficos que representam diferentes análises para que o RDP5 encontre a provável sequência recombinante (aquela com as barras mais longas). Muitas vezes, testes diferentes dizem ao programa que sequências diferentes são recombinantes e, portanto, o programa usa um consenso ponderado desses testes. Também não há garantia de que a ponderação relativa dos testes seja precisa.

d) Nos casos em que o RDP afirma que os parentais não se encontram no dataset, é interessante realizar uma análise no TreeOrder Scan (Protocolo Recombinação).

Analisando os resultados dos Gráficos dos Pontos de Recombinação:

a) Ao selecionar uma sequência recombinante em *Overview*, aparecerá no desenho à esquerda um gráfico de recombinação, especificando os breakpoints. As áreas sombreadas em cinza claro e escuro representam, respectivamente, os intervalos de confiança do breakpoint que incluem 99% e 95% dos pontos determinados pelo método BURT (*Breakpoint Uncertainty in Recombined Triplets*).

b) Verifique se os picos em qualquer uma das linhas traçadas correspondem às bordas da região recombinante detectada e mostrada através de um retângulo rosa. Se os picos e as bordas da região recombinante não corresponderem, isso não significa necessariamente que as posições do ponto de interrupção inferidas estão erradas. Isso significa, no entanto, que há um certo grau de incerteza quanto à posição.

c) Outra análise importante é olhar para a região do alinhamento onde o RDP está atribuindo os breakpoints. Verifique se estas regiões não são ricas em N, ou muito variáveis e mal alinhadas. Se sim, mascare essa região e repita a análise.

d) Os melhores métodos para especificar a localização dos breakpoints são BOOTSCAN, 3SEQ, MAXCHI e CHIMAERA. No entanto, percebe-se que MAXCHI e CHIMAERA possuem o maior

poder para detectar recombinação. Selecione o método através da flecha entre as opções, logo ao lado do gráfico.

e) Veja os gráficos para alguns dos outros métodos. Os limites da região recombinante em rosa devem corresponder às posições nos gráficos RDP, BOOTSCAN, RECSCAN, SISCAN, VisRD Occupacy e DISTANCE PLOT onde duas das três linhas traçadas se cruzam. Tal como acontece com o gráfico MAXCHI, os limites da região rosa devem corresponder aos picos em pelo menos uma das linhas nos gráficos CHIMAERA, TOPAL DSS, PHYLPRO ou LARD. Para o gráfico 3Seq, um dos limites da região rosa deve corresponder a um pico e o outro a um vale. Os gráficos de VisRD HIGHWAY e GENECONV não são particularmente úteis para identificar posições de pontos de interrupção de recombinação potenciais.

f) Outra ferramenta interessante para entender sobre os pontos de recombinação são através das matrizes geradas pelos métodos MAXCHI e LARD. Essa matrizes mostram graficamente as probabilidades de todos os potenciais pares de breakpoints. Para isso, no canto superior, à direita, selecione *Matrices*. Os pontos em vermelho marcam os pares de breakpoints com maior probabilidade e, ao clicar nestes pontos, você poderá ver a correspondência no gráfico de recombinação. Se você quiser visualizar a matriz gerada pelo LARD, clique com o botão direito sobre a matriz e selecione *Change Matrix type*. Selecione *LARD breakpoint matrix* e o programa avisará que gerar essa matriz pode ser demorado, clique “sim” se desejar continuar ou “não” caso não queira.

g) Caso, neste momento, você NÃO esteja satisfeito com as posições dos breakpoints encontrados pelo programa, é possível readequar a posição de breakpoint e reanalisar todo o *dataset* considerando essa nova informação. Para isso, com o evento de recombinação adequado selecionado, clique na seta circular localizada ao lado da janela que exibe as sequências até encontrar a opção *Show relevant sequences*. Agora, na janela das sequências, você poderá especificar onde estão os prováveis pontos de recombinação clicando com o botão direito do mouse na posição e selecionando *Place beginning breakpoint here* e *Place ending breakpoint here*. Idealmente, você deve colocar o breakpoint entre dois nucleotídeos variáveis, um indicando um relacionamento próximo com uma das sequências parentais e o outro, um relacionamento próximo a outra sequência parental.

h) Você pode também selecionar a opção *Breakpoint Distribution Plot* em *Run*. Através desse gráfico é possível observar regiões do genoma com mais *breakpoints*. É importante fazer essa visualização antes e depois de definir os eventos que serão aceitos/rejeitados.

i) Em *Breakpoint p-val Distribution Plot* você visualizará as regiões associadas aos valores p. Este gráfico mostra onde há concentração de evidência estatística para recombinação. Quanto mais negativo o valor em y, menor o p-value e maior a evidência estatística. No entanto, as regiões com maior significância podem estar associadas à problema de alinhamento, muita variabilidade local, desequilíbrio de amostragem, eventos aninhados ou se for região com forte estrutura filogenética.

Análises Adicionais - Plot de Distribuição de *Breakpoints*:

a) Para fazer um plot incluindo todos os possíveis locais de recombinação vá em *Run* > *breakpoint distribution plot*.

b) A linha preta neste gráfico representa o número de pontos de interrupção de recombinação (individualmente indicados por linhas verticais acima do gráfico) que se enquadram nos nucleotídeos do genoma (coordenadas indicadas no eixo x, correspondendo a sítios de nucleotídeos dentro da primeira sequência no conjunto de dados analisado). As áreas cinza e branca, respectivamente, representam o intervalo de confiança de 95% e 99% dos graus esperados de agrupamento de ponto de interrupção sob recombinação aleatória. Enquanto coordenadas do genoma em que a linha preta surge acima da área branca / cinza são pontos de acesso de recombinação com suporte estatístico, aqueles onde a linha preta fica abaixo da área branca / cinza são pontos frios de recombinação com suporte estatístico.

Análises Adicionais - Plot de Posição do Genoma e os *Breakpoints*:

a) Se você tiver um arquivo GenBank disponível que contenha informações sobre as localizações dos limites do gene, então também é possível testar associações entre breakpoints e organização do genoma.

b) Clique em *Open*, depois de já ter carregado as sequências, e selecione o arquivo txt com informações a respeito das posições do gene no genoma (busque um genoma completo no GenBank e salve como *GenBank Full*).

c) Quando este arquivo é carregado no RDP5, você deve notar que uma série de setas são adicionadas ao mapa de similaridade colorido acima da exibição da sequência. Aperte a seta ao lado do botão *Run* e selecione novamente a opção de menu *Breakpoint Distribution plot*gráfico. Além disso, para exibir o gráfico de distribuição do ponto de interrupção, informações extras são tabuladas no painel de informações de recombinação no canto

superior direito. Esta informação extra está relacionada ao agrupamento relativo de pontos de interrupção entre (1) regiões codificantes e não codificantes, (2) entre diferentes genes, e (3) entre diferentes partes dos genes.

d) Neste gráfico as regiões específicas do genoma que estão sendo comparadas em cada linha são representados graficamente em laranja e azul. Os números na tabela são coloridos de acordo com as regiões do genoma às quais se relacionam.

Análises Adicionais - Filogenias I:

a) Uma maneira de identificar sequências com evidência do mesmo evento de recombinação ancestral é gerar e comparar gráficos BOOTSCAN ou RDP com diferentes sequências recombinantes potenciais, usando as mesmas sequências parentais.

b) Para isso, faça uma lista de sequências que o programa indicou conter evidências de um evento de recombinação semelhante.

c) Selecione os gráficos BOOTSCAN ou RDP no menu suspenso *Checking using* na exibição do gráfico.

d) Em uma das árvores, mova o ponteiro do mouse sobre um dos nomes de sequência que você tem em sua lista, pressione o botão direito do mouse e selecione a opção *Recheck plot with SEQUENCE NAME... as recombinant*. Isso irá comparar os gráficos da sequência atualmente selecionada (geralmente a sequência que contém a "melhor" evidência do evento de recombinação atual) com uma das sequências em sua lista. Os resultados da comparação são exibidos graficamente na forma de uma linha colorida acima do gráfico.

e) Azul neste gráfico indica regiões de sequência onde os sinais de recombinação são altamente semelhantes e vermelho escuro indica regiões de sequência onde os sinais de recombinação são completamente diferentes. Se a porção da sequência que abrange um ou ambos os pontos de interrupção de recombinação corresponder a um sinal azul / verde, então o padrão de locais compartilhados pelas sequências sendo comparadas e suas supostas sequências parentais são muito semelhantes e possivelmente derivadas aproximadamente ao mesmo tempo da mesma ou fontes semelhantes.

Análises Adicionais - Filogenias II:

a) Se você está convencido de que RDP4 perdeu evidências de que um grupo de sequências descendeu de um ancestral comum recombinante ou identificou incorretamente que um grupo

de sequências recombinantes descendeu de um ancestral recombinante comum, a situação pode ser remediada por meio da exibição da árvore.

b) Em uma das árvores, mova o ponteiro do mouse sobre um dos nomes de sequência que foram incluídos ou excluídos incorretamente como evidência de compartilhamento do evento de recombinação atual. Pressione o botão direito do mouse e a primeira opção no menu que aparece será marcar a sequência que você selecionou como tendo ou não tendo evidências do evento de recombinação atual sendo analisado.

c) Em seguida, selecione a opção apropriada e a sequência será adicionada ou removida da lista de sequências contendo evidências desse evento.

Referências:

1. Martin DP, Varsani A, Roumagnac P, Botha G, Maslamoney S, Schwab T, Kelz Z, Kumar V, & Murrell B. RDP5: A computer program for analyzing recombination in, and removing signals of recombination from, nucleotide sequence datasets. Virus Evolution, vol 7, 2021.

2. Padidam, M., Sawyer, S. & Fauquet, C. M. Possible emergence of new geminiviruses by frequent recombination. Virology, vol 265, 1999.

3. Martin, D. P., Posada, D., Crandall, K. A. & Williamson, C. A modified bootscan algorithm for automated identification of recombinant sequences and recombination breakpoints. AIDS Res Hum Retroviruses, vol 21, 2005.

4. Maynard Smith, J. Analyzing the mosaic structure of genes. J Mol Evol, vol 34, 1992.

5. Posada, D. & Crandall, K. A. Evaluation of methods for detecting recombination from DNA sequences: Computer simulations. Proc Natl Acad Sci, vol 98, 2001.

6. Gibbs, M. J., Armstrong, J. S. & Gibbs, A. J. Sister-Scanning: a Monte Carlo procedure for assessing signals in recombinant sequences. Bioinformatics, vol 16, 2000.

7. Lam H.M., Ratmann O., Boni M.F. Improved algorithmic complexity for the 3SEQ recombination detection algorithm. Mol Biol Evol, vol 35, 2018.

8. RDP5, disponível em: https://web.cbio.uct.ac.za/~darren/rdp.html

ANEXO I

CheckList de Validação de Eventos de Recombinação

Protocolo de análise desenvolvido por Dennis Maletich Junqueira e Sandro Rodrigo Martins Sobrinho e revisão final conduzida por Dennis Maletich Junqueira

Sumário:

Objetivo da Análise 15
Observações 15
Fase 01 – Curadoria do alinhamento 16
Fase 02 – Homoplasia e saturação 16
Fase 03 – Mapeamento global de recombinação: 17
Fase 04 – Detecção de eventos de recombinação: 18
Fase 05 – Análise filogenética dos eventos de recombinação detectados: 20
Fase 06 – Análise dos pontos de recombinação: 21
Fase 07 – Classificação final: 21
Fase 08 – Análise adicional: 24

Objetivo da Análise:

Identificar sequências recombinantes e os respectivos pontos de recombinação.

Observações:

Para rodar as análises de recombinação você precisará dos seguintes arquivos:

a) Alinhamento das sequências no formato fasta. É importante que este alinhamento tenha sido gerado com rigor, especialmente em casos de sequências muito divergentes.

b) Conheça o genoma do seu vírus e saiba quais regiões são provavelmente mais suscetíveis aos eventos de recombinação. Essas informações podem ajudar na interpretação dos resultados no RDP.

c) Este *CheckList* foi organizado na ordem em que os programas devem ser utilizados.

d) Este *CheckList* inclui análises do SplitsTree, RDP5, TreeOrder (script em R) e Simplot. Adicionalmente, árvores de máxima verossimilhança são necessárias.

e) Este *CheckList* foi primariamente desenvolvido para detectar eventos de recombinação (e os respectivos pontos de recombinação) em sequências de genótipos diferentes. No

entanto, sempre que possível, o protocolo elenca possibilidades para restringir as análises e detectar sinais de recombinação intraclado/intragenótipo. O mesmo raciocínio se aplica para eventos de recombinação muito recentes.

Fase 01 – Curadoria do alinhamento:

a) Preparação:

- Gerar alinhamento de alta qualidade (preferencialmente *codon-aware* para sequências codificantes). Programas como Prank ou mafft (L-ins-i ou E-ins-i se houverem muitas regiões com gaps) são capazes de gerar este tipo de alinhamento. A identificação final no Aliview também pode ser necessária.
- Verificar consistência de leitura, ausência de *frameshifts* e regiões mal alinhadas.
- Os subtópicos devem acabar com um ponto final.

b) Mascaramento:

- Regiões com alta concentração de gaps ou Ns devem ser mascaradas por completo. O mascaramento consiste na alteração destas regiões por N (faça o mascaramento no Aliview, selecionando a região desejada e apertando N).
- Mascarar regiões de alinhamento ambíguo, ou seja, regiões onde não é possível afirmar com confiança quais posições entre as sequências são realmente homólogas. Essas regiões podem ser identificadas utilizando o trimAl ou Gblocks.

c) Redução de Redundância (opcional, dependente do objetivo):

- Reduzir quase-duplicatas para minimizar viés amostral (heurística ~1–2%).
- Manter sequências próximas caso o foco seja recombinação recente.

Fase 02 – Homoplasia e saturação:

a) Realizar uma análise para verificar homoplasia e saturação nas sequências. Utilize o script R 002R118_Sequencia_HomoplasiaSaturacao.R.

b) Um dos resultados gerados pelo script acima é um arquivo csv contendo informações sobre o CI_global (*Consistency Index*), que mede quantas mudanças são necessárias *vs* observadas, e o RI_global (*Retention Index*), que mede quanto da estrutura filogenética ainda está sendo preservada apesar da homoplasia. Valores baixos de CI indicam alta homoplasia; como regra prática, valores < 0.5 sugerem homoplasia elevada, mas devem ser interpretados no contexto do tamanho e diversidade do dataset. Valores baixos de RI indicam perda de estrutura filogenética devido à homoplasia e/ou outros processos evolutivos (valores > 0.7 sugerem

boa estrutura e < 0.6 muita homoplasia/ruído). Se o dataset apresentar CI baixo + RI baixo, há forte indício de homoplasia, estrutura populacional ou recombinação.

c) Para saturação, observe os gráficos resultantes do script (global_pdist_vs_corrected, global_transicoes e global_transversoes). Quando não há saturação, as transições aumentam de forma contínua (quase linear). Por outro lado, um sinal de saturação é representado pela presença de um platô no gráfico. Esse platô mostra que múltiplas mutações ocorreram no mesmo sítio e, e virtude disso, há perda de informação evolutiva. Para o caso das transversões, o aumento é mais lento e a saturação mais demorada (se houver). Finalmente, no gráfico _pdist_vs_corrected, observe se os pontos apresentam uma relação quase linear para atestar ausência de saturação. Se p-distance para de aumentar e a distância corrigida continua aumentando, temos um sinal forte de saturação. Por último, observe os resultados para as posições dos códons, posições com baixa correlação sugerem maior saturação e perda de sinal evolutivo.

d) A partir destes resultados acima, avalie os cenários:

- Saturação alta: transições saturando, p-distance não linear, 3° posição altamente saturada. Conclusão: o alinhamento perdeu sinal filogenético em partes do genoma. Impacto: árvores por blocos podem ser falsas, TreeOrder Scan pode mostrar instabilidade artificial, RDP pode gerar falso positivo. Ação: considerar remover a 3° posição, usar janelas maiores no TreeOrder, interpretar recombinação com cautela
- Homoplasia alta: CI baixo (< 0.5), RI baixo. Conclusão: mutações independentes. Impacto: PHI-test pode indicar incompatibilidade de sítios na ausência de recombinação, RDP detecta eventos inconsistentes, árvores não concordam.
- Saturação e homoplasias altas: falso mosaico evolutivo (padrão que simula recombinação, mas resulta de homoplasia e saturação).

e) Para casos de saturação alta, não confiar em eventos curtos e exigir mais evidência filogenética. Se homoplasia alta, exigir filogenias de máxima verossimilhança com suporte forte e reduzir o peso de métodos de similaridade.

Fase 03 – Mapeamento global de recombinação:

a) Realizar PHI-test (Splitstree) como triagem preliminar de sinal global de recombinação (a ferramenta detecta incompatibilidade de sítios, mas não separa bem recombinação e homoplasia), interpretando resultados com cautela em *datasets* com forte estrutura populacional. Um PHI-test negativo não significa ausência de recombinação.

b) Analise seu alinhamento com o script 002R114_Recombinacao_TreeOrderScan_v2 (Versão em R do TreeOrder), testando diferentes combinações de janelas (curta 2,5% pares de base do alinhamento, intermediária 7% e longa 14%) e step sizes (entre 10 e 20% da janela). Defina qual será a janela e o *step size* da análise com base na estabilidade do RF_mean (instabilidade excessiva pode prejudicar as análises e estabilidade excessiva pode criar um viés). Conhecer regiões do genoma com maior taxa de recombinação pode ajudar nesta etapa. Esta ferramenta não constitui evidência isolada de recombinação, sendo utilizada como suporte para identificação de incongruência filogenética ao longo do genoma.

Fase 04 – Detecção de eventos de recombinação:

a) Rodar o RDP5 com parâmetros definidos (consultar o tópico Configurando a Análise deste protocolo, página 2) e avaliar os critérios abaixo para cada eventos de recombinação detectado:

- Avaliar o valor-p: Os possíveis eventos de recombinação devem apresentar um valor-p < 0.05 (com correção de Bonferroni/FDR) em no mínimo "X" diferentes métodos (definir este valor). Eventos reais recentes ou fragmentos menores podem ser detectados por 1–2 métodos apenas; no entanto, se exigir ≥ 3 métodos, você aumenta especificidade. O aumento de especificidade, por outro lado, pode levar a perda de sinal de recombinação intragenótipo recente e/ou eventos com pouco contraste parental. Para casos em que é desejado ser mais criterioso, é possível ainda definir a significância não apenas pela quantidade de métodos, mas pela família dos métodos, já que métodos da mesma família tendem a chegar a resultados similares [métodos baseados em similaridade/distância (BOOTSCAN, SISCAN, RDP e 3Seq parcialmente), métodos baseados em incompatibilidade de sítios (MAXCHI, CHIMAERA e GENCONV) e métodos baseados em modelos probabilísticos exatos (3Seq). Em trabalhos anterior, utilizamos 3 métodos de no mínimo duas famílias diferentes.
- Verificar o tamanho do fragmento recombinante. Fragmentos muito curtos devem ser desconsiderados. Fragmentos devem conter número suficiente de sítios informativos para suportar inferência filogenética robusta.
- Sempre que metadados confiáveis estiverem disponíveis, avaliar plausibilidade temporal, geográfica, ecológica e de hospedeiro dos parentais propostos.
- Avaliar a sequência major: Identificar o parental major da recombinação e observar se esta sequência não foi também encontrada como recombinante em outro evento na

mesma posição do genoma (se não for na mesma posição do genoma, desconsiderar esta etapa). Caso isto tenha acontecido, será necessário criar um novo alinhamento em que esta sequência major é excluída. Este novo *dataset* deve ser carregado no RDP5 e uma nova análise com os mesmos parâmetros da análise anterior deve ser conduzida. Se a sequência identificada como recombinante na etapa anterior ainda se encontra identificada como recombinante nesta nova análise, temos efetivamente uma sequência potencialmente recombinante que não depende apenas da sequência major. Caso ela não tenha sido identificada como recombinante, podemos entender como um viés de amostra e; portanto este evento diminui sua confiabilidade.

- Avaliar a presença de parentais major e *minor*: Verificar se ambos parentais foram identificados na análise. Caso um dos parentais não esteja, lembre-se de avaliar a etapa abaixo (Avaliar as filogenias) buscando a evidência de troca topológica entre as filogenias).

- Avaliar as filogenias: Nas filogenias reconstruídas pelo RDP5 (por *default*, filogenias de *neighbor-joining*), observe se a sequência recombinante agrupa com o parental major, na filogenia do fragmento não recombinante (figura de filogenia à esquerda) e com a parental *minor* na filogenia do fragmento recombinante (figura de filogenia à direita). Se não há recombinantes com o mesmo padrão de recombinação temos um Singleton. No entanto, é necessário também observar se existe mais de uma sequência recombinante elencada pelo RDP5 no mesmo evento. Se existir, observar se estas sequências estão no mesmo clado ou não, já que, na verdade, o ancestral dessas sequências é que seja o verdadeiro recombinante e não as próprias sequências (recombinação ancestral). Nesses casos, verifique se as sequências “andam” em conjunto nas duas árvores. Se sim, o ideal é rodar um BootScan utilizando as sequências *major* e *minor* como referências e apenas mudar a *query* entre as possíveis recombinantes (espera-se que todas tenham um mesmo sinal no BootScan para uma recombinação ancestral). Se as sequências não andam juntas, o melhor é criar um novo alinhamento, retirando as sequências mais próximas da recombinante e rodar uma nova análise no RPD5. Repita a reconstrução do alinhamento para todas as sequências do evento. Se o sinal de recombinação para estas sequências desaparecer, provavelmente se trata de um viés de estrutura/proximidade e não efetivamente de recombinação. No entanto, se houver persistência do sinal, há o favorecimento do evento ancestral. Outra análise para

entender a recombinação ancestral é observar o comportamento do grupo no TreeOrder Scan.

- Avaliar os *breakpoints*: Observar as regiões de recombinação, clicando na aba *Overview*. As áreas sombreadas em cinza claro e escuro representam, respectivamente, os intervalos de confiança do breakpoint que incluem 99% e 95% dos pontos determinados pelo método BURT (*Breakpoint Uncertainty in Recombined Triplets*). Verifique se os picos em qualquer uma das linhas traçadas correspondem às bordas da região recombinante detectada e mostrada através de um retângulo rosa (observe também os gráficos gerados pelo RDP, BOOTSCAN, RECSCAN, SISCAN, VisRD *Occupacy* e DISTANCE PLOT). Se não corresponderem, espere um certo grau de incerteza quanto à posição. Olhe também para o alinhamento, na região que o RDP está atribuindo os breakpoints (região com Ns, gaps ou alinhamento ruim podem ser problemáticas). Se o ponto de recombinação coincidir com uma região cheia de gaps ou com muitos Ns, é aconselhável mascarar a região e rodar o RDP5 novamente para verificar se o evento se mantém. Por último, para análise dos pontos de recombinação, selecione a aba *Matrices* e coloque o mouse sobre as posições em vermelho (mostram os pares de regiões com maior probabilidade de recombinação). Se necessário, você pode mudar as posições dos *breakpoints* (consulte protocolo RDP5).

- Avaliar regiões do genoma com mais breakpoints: selecione *Breakpoint Distribution Plot* em *Run* e observe as regiões com maior chance de breakpoints. Da mesma forma, rode a análise Breakpoint p-val Distribution Plot.

Fase 05 – Análise filogenética dos eventos de recombinação detectados:

a) Para cada evento candidato, construir filogenias de máxima verossimilhança com suporte estatístico dado por aLRT, bootstrap (B) ou ultrafastbootstrap (UFB) utilizando tanto o fragmento não recombinante (antes e depois do breakpoint) como o fragmento recombinante. Observe se existe suporte (aLRT > 80, B > 70 ou UFB > 90) no agrupamento da sequência recombinante com o parental major na filogenia do fragmento não recombinante e agrupamento da sequência recombinante com o parental *minor* na filogenia do fragmento recombinante. Marque os parentais nas duas filogenias e verifique se existem uma separação filogenética clara entre eles e se a potencial sequência recombinante muda de clado entre as duas filogenias. Caso um dos parentais não esteja presente na amostra, lembre-se de avaliar

as filogenias buscando pela evidência contundente de troca topológica suportada por valores de confiabilidade nos nós.

Fase 06 – Análise dos pontos de recombinação:

a) Para cada um dos eventos de recombinação detectados no RDP5, rodar uma análise de *Bootscan* incluindo os dois ou três primeiros parentais *major* e os dois ou três parentais *minor*. Sempre inclua na análise a própria sequência recombinante e uma sequência distante, nada relacionada com o evento. Se o RDP5 não foi capaz de identificar um dos parentais, buscar as sequências mais próximas nas árvores filogenéticas de máxima verossimilhança.

- Avaliar o sinal de *Bootscan*: Inicialmente, verificar a região de recombinação estimada pelo RDP5 e analisar se esta mesma região, no *Bootscan*, mantém um sinal estável e relacionado a uma das sequências *minor* incluídas na análise. Importante lembrar que recombinação intraclado/intragenótipo pode não ter um cruzamento tão claro de linhas e as curvas podem aparecer quase sobrepostas.

b) No gráfico gerado TreeOrder Scan (script R), verifique se a região potencialmente recombinante, identificada pelo RDP5, contém instabilidade no gráfico individual da sequência.

Fase 07 – Classificação final:

A classificação das sequências recombinantes pode se dar da seguinte forma:

- **Recombinante confirmado** (alta confiança):
  - ≥3 métodos de duas famílias diferentes com valor-p significativo no RDP5 &
  - Tamanho do fragmento recombinante compatível &
  - Posição do breakpoint não associada a região com N e/ou gaps &
  - Relações temporais e geográficas das sequências parentais biologicamente compatíveis &
  - Sequência *major* não recombinante na região do evento de recombinação ou, quando recombinante, após sua exclusão do dataset, a potencial sequência recombinante manteve-se como tal &
  - Posições nas filogenias reconstruídas pelo RDP5 compatíveis com sinal de recombinação (tanto em casos de *singleton* quanto em casos de recombinação ancestral) &

- Posições nas filogenias de máxima verossimilhança são compatíveis com sinal de recombinação encontrado nas filogenias do RPD5 e os agrupamentos são suportados por valores significantes de confiança dos nós (aLRT > 80, B > 70 ou UFB > 90) &
- Posições estimadas para os breakpoints não se trata de regiões mascaradas ou regiões incongruentes &
- *Breakpoint* estimado pelo RDP5 em zona compatível com BootScan estável & TreeOrder (script R).

- **Recombinante muito provável** (média-alta confiança):
  - ≥3 métodos de duas famílias diferentes com valor-p significativo no RDP5 &
  - Tamanho do fragmento recombinante compatível &
  - Posição do breakpoint não associada a região com N e/ou gaps &
  - Relações temporais e geográficas das sequências parentais biologicamente compatíveis &
  - Sequência *major* não recombinante na região do evento de recombinação ou, quando recombinante, após sua exclusão do dataset, a potencial sequência recombinante manteve-se como tal &
  - Posições nas filogenias reconstruídas pelo RDP5 compatíveis com sinal de recombinação (tanto em casos de *singleton* quanto em casos de recombinação ancestral) &
  - Posições nas filogenias de máxima verossimilhança são compatíveis com sinal de recombinação encontrado nas filogenias do RPD5 e os agrupamentos são suportados por valores significantes de confiança dos nós (aLRT > 80, B > 70 ou UFB > 90) &
  - Posições estimadas para os breakpoints não se trata de regiões mascaradas ou regiões incongruentes &
  - *Breakpoint* estimado pelo RDP5 em zona compatível com BootScan estável &/OU TreeOrder (script R).

- **Recombinante provável** (média-baixa confiança):
  - ≥3 métodos de duas famílias diferentes com valor-p significativo no RDP5 &
  - Tamanho do fragmento recombinante compatível &

- Posição do breakpoint não associada a região com N e/ou gaps &
- Relações temporais e geográficas das sequências parentais biologicamente compatíveis &
- Sequência *major* não recombinante na região do evento de recombinação ou, quando recombinante, após sua exclusão do dataset, a potencial sequência recombinante manteve-se como tal &
- Posições nas filogenias reconstruídas pelo RDP5 compatíveis com sinal de recombinação (tanto em casos de *singleton* quanto em casos de recombinação ancestral) &
- Posições nas filogenias de máxima verossimilhança NÃO são compatíveis com sinal de recombinação encontrado nas filogenias do RPD5 e/OU os agrupamentos NÃO são suportados por valores significantes de confiança dos nós (aLRT > 80, B > 70 ou UFB > 90) &
- Posições estimadas para os breakpoints não se trata de regiões mascaradas ou regiões incongruentes &
- *Breakpoint* estimado pelo RDP5 em zona compatível com BootScan estável &/OU TreeOrder (script R).

- **Recombinante improvável**:
  - ≥3 métodos de duas famílias diferentes com valor-p significativo no RDP5 &
  - Tamanho do fragmento recombinante compatível &/OU
  - Posição do breakpoint associada a região com N e/ou gaps &/OU
  - Relações temporais e geográficas das sequências parentais biologicamente compatíveis &
  - Sequência *major* não recombinante na região do evento de recombinação ou, quando recombinante, após sua exclusão do dataset, a potencial sequência recombinante manteve-se como tal &
  - Posições nas filogenias reconstruídas pelo RDP5 NÃO compatíveis com sinal de recombinação (tanto em casos de *singleton* quanto em casos de recombinação ancestral) &/OU
  - Posições nas filogenias de máxima verossimilhança NÃO são compatíveis com sinal de recombinação encontrado nas filogenias do RPD5 e/OU os

agrupamentos NÃO são suportados por valores significantes de confiança dos nós (aLRT > 80, B > 70 ou UFB > 90) &

- Posições estimadas para os breakpoints não se trata de regiões mascaradas ou regiões incongruentes &
- *Breakpoint* estimado pelo RDP5 em zona compatível com BootScan estável &/OU TreeOrder (script R).

- **Não recombinantes**:
  - Todos os demais casos

Fase 08 – Análise adicional:

a) Avaliar a relação entre a distância genética dos parentais e a ocorrência de eventos de recombinação, testando se parentais mais divergentes apresentam menor frequência de recombinação. Para cada evento, delimitamos a região recombinante (incluindo intervalo de confiança para as posições dos *breakpoints*) e isolamos este trecho na sequência do parental major e na sequência do parental *minor* e calculamos a distância genética entre elas.

b) Em casos de recombinação que envolvem um clado inteiro, o RDP estima os breakpoints individualmente para cada uma das sequências, quando, na verdade, provavelmente a sequência ancestral daquele clado é que recombinou uma única vez. Desta forma, para definir uma única região de recombinação para todo o clado, podemos analisar regiões de alto RF_mean em análises de TreeOrder. Essas regiões definem blocos genômicos coerentes, que podem ser tratados como unidades recombinantes ("módulos") compartilhadas por todo o clado.

c) Será preciso construir uma tabela com as seguintes informações: event_id, recombinant, major_parent, minor_parent, start, end, geneticDistance (opcional: p-values, métodos). A análise a ser realizada deve agrupar os eventos por faixas de distância genética (bins), contar quantos eventos caem em cada bin e fazer uma regressão: log(count) ~ distance.